


Πολυτεχνική Σχολή

Τμήμα Μηχανικών Η/Υ & Πληροφορικής

**ΕΞΟΡΥΞΗ ΔΕΔΟΜΕΝΩΝ ΚΑΙ ΑΛΓΟΡΙΘΜΟΙ ΜΑΘΗΣΗΣ**

---

# Βελτιστοποίηση της Εξόρυξης Γνώσης με Περιορισμούς, Αποδοτικότητα και Πολλαπλά Κατώφλια

---

Κιουρτ-Μεχμεταλή Αχμέτ

Α.Μ. 1084672

Πάτρα, 2025

# 1 Εισαγωγή

Η ανάπτυξη τεχνικών εξόρυξης γνώσης από δεδομένα (data mining) αποτελεί ένα από τα πιο κρίσιμα εργαλεία για τη σύγχρονη ανάλυση πληροφορίας. Η ταχύτητα με την οποία παράγονται, αποθηκεύονται και επεξεργάζονται τα δεδομένα στον σημερινό ψηφιακό κόσμο καθιστά αναγκαία την ύπαρξη μηχανισμών που όχι μόνο μπορούν να αναγνωρίσουν μοτίβα και συσχετίσεις, αλλά και να εξάγουν ουσιαστική γνώση με επιχειρηματική ή επιστημονική αξία. Ένα βασικό υποσύνολο του data mining είναι η εξόρυξη συσχετιστικών κανόνων (Association Rules Mining – ARM), η οποία επιτρέπει την αναγνώριση συσχετίσεων μεταξύ διαφορετικών αντικειμένων μέσα σε μεγάλους όγκους δεδομένων.

Οι παραδοσιακές τεχνικές ARM, όπως οι αλγόριθμοι Apriori και FP-Growth, βασίζονται κυρίως στη συχνότητα εμφάνισης των αντικειμένων. Αυτό σημαίνει ότι η ανάλυση βασίζεται στο πόσο συχνά συνυπάρχουν ορισμένα στοιχεία σε μια βάση δεδομένων, αδιαφορώντας για ποιοτικά χαρακτηριστικά όπως η αξία, η κερδοφορία ή το κόστος. Αυτή η προσέγγιση, ενώ έχει εφαρμοστεί επιτυχώς σε αρκετές περιπτώσεις, παρουσιάζει σοβαρά μειονεκτήματα, ειδικά όταν το περιβάλλον ανάλυσης είναι πιο σύνθετο – για παράδειγμα, όταν ένα σπάνιο προϊόν φέρνει μεγάλο κέρδος ή όταν οι χρήστες ενδιαφέρονται για συγκεκριμένους τύπους σχέσεων και όχι για όλες τις πιθανές συσχετίσεις.

Στο πλαίσιο αυτό, η ερευνητική κοινότητα έχει αναζητήσει τρόπους βελτίωσης των υπαρχουσών τεχνικών. Οι τέσσερις εργασίες που μελετώνται στην παρούσα ανάλυση συμβάλλουν στην εξέλιξη αυτών των τεχνικών από διαφορετικές οπτικές γωνίες:

- Η προσθήκη πολλαπλών περιορισμών στον αλγόριθμο ARM, έτσι ώστε να μειώνεται ο αριθμός των ασήμαντων κανόνων και να αυξάνεται η σχετικότητα των αποτελεσμάτων για τον χρήστη.
- Η ενσωμάτωση πολλαπλών ελάχιστων υποστηρίξεων (MMS) στην ταξινόμηση βάσει συσχετίσεων (CBA), προκειμένου να αντιμετωπίζεται το πρόβλημα των σπάνιων αντικειμένων (rare item problem).
- Η εξόρυξη κανόνων υψηλής αποδοτικότητας (HEIM), που εισάγει την έννοια του λόγου κέρδους προς επένδυση και αντιμετωπίζει την έλλειψη ρεαλισμού του high-utility mining.
- Η εφαρμογή πολλαπλών χρηστικών κατωφλίων (MHUI-MUT), που αντικαθιστά το ενιαίο κατώφλι χρησιμότητας με διαφοροποιημένα όρια ανά αντικείμενο και υιοθετεί παραλληλοποίηση για βελτίωση της απόδοσης.

Η σταδιακή μετάβαση από τις απλές μεθόδους εξόρυξης συχνοτήτων προς πιο σύνθετα και επιχειρηματικά χρήσιμα μοντέλα αναδεικνύει τον προσανατολισμό της σύγχρονης επιστημονικής έρευνας στην κατεύθυνση της ποιοτικής κατανόησης των δεδομένων.

## 1.1 Σκοπός

Ο γενικός σκοπός αυτής της μελέτης είναι να αναδείξει τη σημασία της προσαρμογής των αλγορίθμων εξόρυξης κανόνων στις ανάγκες του πραγματικού κόσμου. Οι κλασικές τεχνικές ARM και HUIM βασίζονται σε απλοποιημένες παραδοχές, όπως η ομοιογένεια των αντικειμένων και η έλλειψη ποιοτικών χαρακτηριστικών. Στην πραγματικότητα όμως, τα αντικείμενα σε ένα dataset μπορεί να έχουν διαφορετική πιθανότητα

εμφάνισης. Συνεπώς, η ανάγκη προσαρμογής των εξορυκτικών μεθόδων σε πιο σύνθετα περιβάλλοντα είναι επιτακτική.

Οι προσεγγίσεις που αναλύονται επιχειρούν να επιλύσουν διαφορετικές, αλλά αλληλένδετες προκλήσεις:

- Η εισαγωγή περιορισμών στο ARM, με στόχο να εξαιρούνται από την εξόρυξη μη σχετικές ή ανεπιθύμητες συσχετίσεις, δίνει στον χρήστη μεγαλύτερο έλεγχο στο αποτέλεσμα. Η συνδυαστική χρήση μονοτονικών και αντι-μονοτονικών περιορισμών (π.χ. min(price), max(cost)) βοηθά στον περιορισμό του χώρου αναζήτησης.
- Η χρήση πολλαπλών τιμών ελάχιστης υποστήριξης στη δημιουργία ταξινόμησης επιτρέπει την εύρεση σημαντικών κανόνων που περιλαμβάνουν σπάνια αντικείμενα, χωρίς να πλημμυρίσει το σύστημα από άχρηστους συνδυασμούς.
- Η έννοια της αποδοτικότητας (efficiency), δηλαδή του λόγου κέρδους προς επένδυση, φέρνει ένα πιο επιχειρηματικό κριτήριο στο προσκήνιο, και συνδέεται άμεσα με πραγματικά μοντέλα αγοράς και πώλησης, δηλαδή βοηθά στο τρόπο που θα πρέπει να κατανοήσουμε την σωστή απόδοση των αλγορίθμων
- Η εφαρμογή διαφορετικών χρηστικών κατωφλίων (utility thresholds) ανά προϊόν αναγνωρίζει ότι τα προϊόντα σε μια βάση δεδομένων δεν έχουν την ίδια εμπορική βαρύτητα. Αυτό επιτρέπει πιο ευέλικτους και ρεαλιστικούς κανόνες, ιδιαίτερα όταν εφαρμόζεται παράλληλα με τεχνικές επιτάχυνσης όπως η παραλληλοποίηση επεξεργασίας. Με αυτό τον τρόπο ουσιαστικά μπορούμε να έχουμε και καλύτερη προσέγγιση ακόμα και για τα προϊόντα που δεν έχουν την καλύτερη αξία, αλλά και να εφαρμόσουμε αλγορίθμους που θα περιλαμβάνει αυτές τις έννοιες με χρήση όλων των άχρηστων δεδομένων μαζί για ένα καλύτερο αποτέλεσμα.

Έτσι, η εργασία στοχεύει στη συνολική κατανόηση των βελτιωμένων τεχνικών ARM και HUIM, ώστε να προταθούν τεχνολογικές λύσεις πιο κοντά στις απαιτήσεις του σημερινού περιβάλλοντος δεδομένων.

## 1.2 Στόχος

Η εργασία αυτή έχει ως κύριο στόχο την κατανόηση των σύγχρονων μεθόδων εξόρυξης γνώσης που ενσωματώνουν περιορισμούς και ποιοτικά κριτήρια στον τύπο και τη συμπεριφορά των δεδομένων. Επιπλέον, αποσκοπεί στη συστηματική χαρτογράφηση των βελτιώσεων που επιφέρουν οι μελετώμενες τεχνικές τόσο σε επίπεδο αποτελεσματικότητας (π.χ. μείωση κανόνων, αύξηση σχετικότητας) όσο και σε επίπεδο αποδοτικότητας (π.χ. μείωση χρόνου, χρήσης μνήμης).

Ο στόχος είναι να κατανοηθεί ο τρόπος με τον οποίο κάθε πρόταση αντιμετωπίζει τις προκλήσεις του πεδίου. Η εισαγωγή της πολλαπλής υποστήριξης, για παράδειγμα, επιχειρεί να καλύψει τις αδυναμίες του κλασικού μοντέλου ARM έναντι των σπάνιων αλλά κρίσιμων αντικειμένων. Αντίστοιχα, η έννοια της αποδοτικότητας ως μέτρο αξιολόγησης των itemsets δίνει μια νέα διάσταση στην αξιολόγηση κανόνων, ιδίως όταν το ζητούμενο είναι όχι απλώς το “τι πουλήθηκε πολύ”, αλλά το “ποιο ήταν συμφέρον να πουληθεί”.

Ακόμη, στόχος είναι να αποσαφηνιστούν οι τεχνικές που χρησιμοποιούνται για την αύξηση της υπολογιστικής αποδοτικότητας των αλγορίθμων, όπως τα upper bounds και η παράλληλη επεξεργασία. Η ανάλυση αυτών των μεθόδων προσφέρει πρακτική γνώση σχετικά με το πώς μπορούν να επιταχυνθούν πολύπλοκοι υπολογισμοί, διατηρώντας παράλληλα υψηλή ποιότητα εξόρυξης.

Εξίσου σημαντικός στόχος είναι να συνδεθούν οι ακαδημαϊκές αυτές προτάσεις με πραγματικά περιβάλλοντα εφαρμογής. Η αξιολόγηση των μεθόδων πάνω σε datasets του UCI, που προσομοιώνουν πραγματικές καταστάσεις, δείχνει ότι οι τεχνικές αυτές μπορούν να χρησιμοποιηθούν σε ηλεκτρονικά καταστήματα, ακόμα και σε τομείς όπως η ιατρική πληροφορική.

Τέλος, μακροπρόθεσμος στόχος είναι η αναγνώριση πιθανών κατευθύνσεων για περαιτέρω έρευνα. Η ενσωμάτωση των παραπάνω τεχνικών με μεθόδους μηχανικής μάθησης η εφαρμογή τους σε streaming δεδομένα και δυναμικές βάσεις, καθώς και η αξιοποίηση τους σε συνθήκες Big Data, αποτελούν προκλήσεις με ιδιαίτερο ερευνητικό ενδιαφέρον. Μέσα από αυτή την εργασία επιχειρείται να τεθεί το πλαίσιο μέσα στο οποίο τέτοιες καινοτομίες μπορούν να αναπτυχθούν.

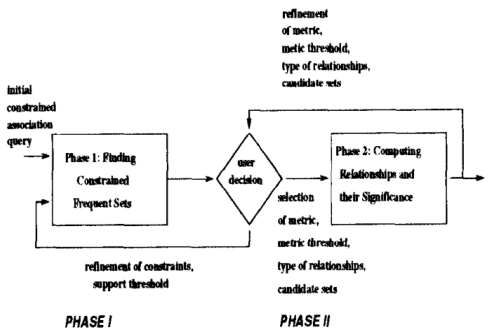
# 2 Προηγούμενες Σχετικές Μελέτες

## 2.1 Κανόνες με Περιορισμούς

Αρχικά ας ξεκινήσουμε την μελέτη από την εργασία " Association Rules Mining with Multiple Constraints" αφού δεν εστιάζει ακόμη στη χρησιμότητα και στην αποδοτικότητα αλλά περιγράφει το πρόβλημα με το φιλτράρισμα που παράγουμε μη efficient αποτελέσματα με χρήση αυτής της μέθοδος. Ουσιαστικά αυτό που προσπαθεί να κάνει είναι να μας εξηγήσει την διαδικασία ενίσχυσης των περιορισμών.

Η πρώτη προηγούμενη σχετική μελέτη θα είναι η [1] που μας περιγράφει τα πρώτα βήματα για το πεδίο της εξόρυξης συσχετιστικών κανόνων με περιορισμούς. Περιέχει user-specified constraints, αυτός ο τρόπος χρησιμοποιεί φίλτρο κατά τη διάρκεια της αναζήτησης με αποτέλεσμα να μειωθεί ο υπολογιστικός φόρτος αλλά και οι παραγμένοι κανόνες. Είναι μια μελέτη που αποτελεί σημείο εκκίνησης για πολλές άλλες μελλοντικές εργασίες που εξετάζει τύποι περιορισμών και τεχνικές αποδοτικής χρήσης pruning.

Όπως αναφερθήκαμε περιέχει μία μέθοδο user-specified constraints που ουσιαστικά αυτό βασίζεται σε μία αρχιτεκτονική των 2 φάσεων για την εξόρυξη συσχετιστικών κανόνων με περιορισμούς.




**Εικόνα 1**. Αρχιτεκτονική για Exploratory Association Mining

Στην φάση 1 της αρχιτεκτονικής έχουμε την εύρεση συχνών συνόλων με περιορισμούς ουσιαστικά ο χρήστης «ρωτά» στο σύστημα να βρει τι είδους κανόνες θέλει να βρει και ποιοι θα είναι οι περιορισμοί για το συγκεκριμένη ενέργεια. Για παράδειγμα να βρει προϊόντα που αγοράζονται μαζί και έχουν πωλήσεις πάνω από κάποιο όριο. Που στην συνέχεια το σύστημα ψάχνει αναλόγως με την θέληση του χρήστη τα αντικείμενα με τους συνδυασμούς που εφαρμόζει.

Σε περίπτωση που δεν ικανοποιούν τα αποτελέσματα τον χρήστη, μπορεί να αλλάξει τους περιορισμούς για καλύτερα αποτελέσματα αναλόγως τα αντικείμενα που θέλει.

Έπειτα, στην φάση 2 γίνεται ο υπολογισμός επιλέγοντας μετρικές όπως το confidence ή το correlation. Το σύστημα επιστρέφει τους πιο σημαντικούς κανόνες βάσει αυτών των ρυθμίσεων, ενώ ο χρήστης μπορεί να επαναλάβει τη διαδικασία αν χρειαστεί.

Στην συνέχεια, η μελέτη [2] επεκτείνει την [1] εργασία, προτείνοντας έναν καλύτερο αλγόριθμο για εξόρυξη που μπορεί να χειριστεί ταυτόχρονα τους μονοτονικούς και αντι-μονοτονικούς περιορισμούς. Που αυτή η εργασία προτείνει το έλεγχο σε κάθε επίπεδο της αναζήτησης.

Έπειτα έχουμε την εργασία [3] που ασχολείται με την εξόρυξη σε πολυδιάστατα δεδομένα, δηλαδή δεδομένα που έχουν περισσότερα πεδία όπως χώρα, ημερομηνία και προϊόν. Με αυτή την εργασία έχουμε ποιο σύνθετα datasets αλλά και μία διαφορετική προσέγγιση για την εξόρυξη δεδομένων. Δηλαδή σε συγκεκριμένα υποσύνολα και συνδυασμούς χαρακτηριστικών.

Η εργασία [4] περιλαμβάνει την έννοια των convertible constraints, που είναι περιορισμοί οι οποίοι δεν είναι μονοτονικοί ή αντι-μονοτονικοί στην αρχική τους μορφή, αλλά μπορούν να μετατραπούν ώστε να χρησιμοποιηθούν σε βελτιστοποιημένες εξορυκτικές διαδικασίες. Αναλύεται πότε ένας περιορισμός μπορεί να μετατραπεί και πώς αυτό επηρεάζει την ταχύτητα και ακρίβεια των αποτελεσμάτων. Η εργασία συμβάλλει θεωρητικά στη γενίκευση του πλαισίου των constraints και επηρεάζει το πώς σχεδιάζονται αλγόριθμοι που βασίζονται σε περιορισμούς, όπως αυτός του Li Guang-yuan.

## 2.2 Ταξινόμηση με Πολλαπλή Υποστήριξη

Στην δεύτερη υποκατηγορία που έχουμε θα μελετήσουμε της προηγούμενες εργασίες για την μελέτη “ Building an Associative Classifier with Multiple Minimum Supports” που αναπτύσσει την ιδέα Multiple Minimum Support η οποία προσπαθεί να δώσει απάντηση στο rare item problem. Η εργασία είναι συνέχεια της λογικής ARM αλλά σε πλαίσιο ταξινόμησης, ποιο συγκεκριμένα σε Classification Based on Association.

Η εργασία [5] ήταν από τις πρώτες που εισήγαγαν την ιδέα της πολλαπλής υποστήριξης. Η βασική παρατήρηση είναι ότι ένα κατώφλι μπορεί να οδηγήσει στον αποκλεισμό σπάνιων αλλά σημαντικών αντικειμένων. Αυτό το γεγονός γνωρίζεται στην ορολογία σαν rare item problem. Που για αυτό το λόγο ξεκίνησε και η χρήση ξεχωριστών κατωφλίων έτσι ώστε η απώλεια να γίνει μικρότερη.

Στην συνέχεια έχουμε την εργασία [6] που συνδυάζει το classification μαζί με το association rule mining δημιουργώντας το associative classification. Δηλαδή αντί να

δημιουργεί μόνο κανόνες για την κατανόηση, αυτοί χρησιμοποιούνται για προβλέψεις των labels.

Για παράδειγμα, έστω ότι έχουμε μία βάση δεδομένων με πληροφορίες για πελάτες και κάθε εγγραφή έχει χαρακτηριστικά όπως:

- Φύλο (ας πούμε ότι A=1 σημαίνει Άνδρας)
- Ηλικία (αυτή η κατηγορία έχει διαστήματα και ας πούμε B=1 ότι σημαίνει 20-30 ετών)
- Κατηγορία (class = 1 σημαίνει «θα αγοράσει προϊόν» )

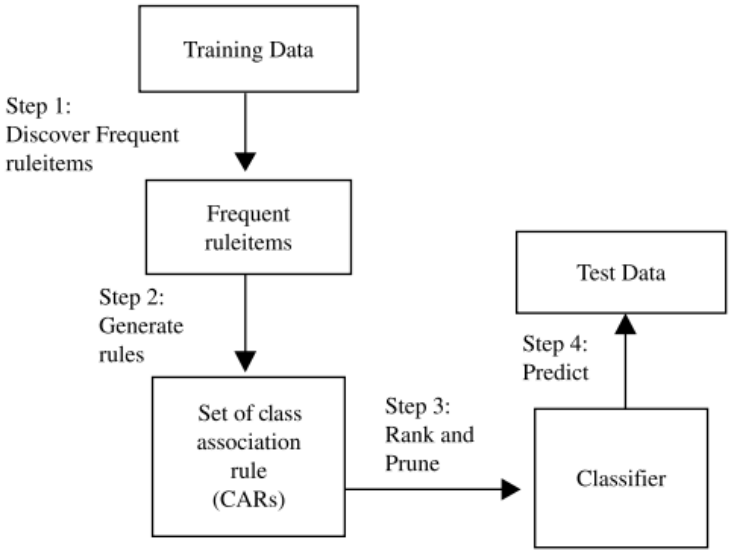
Στο τέλος της επεξεργασίας καταλήγουμε σε:

Αν (A, 1) και (B, 1), τότε class = 1

Αυτό σημαίνει ότι αν ένα άτομο έχει την ιδιότητα A=1 (είναι άνδρας) και επίσης έχει την ιδιότητα B=1 (ανήκει στην ηλικιακή ομάδα 20–30 ετών), τότε το σύστημα προβλέπει ότι ανήκει στην κατηγορία 1, π.χ. «θα αγοράσει προϊόν». Κάθε τέτοιος κανόνας συνοδεύεται από μετρικές όπως support και confidence, που δείχνουν πόσο συχνός και πόσο αξιόπιστος είναι.

Αν μέσα στη βάση δεδομένων υπάρχουν 10 άτομα που είναι άνδρες και ηλικίας 20–30, και από αυτά τα 6 έχουν αγοράσει το προϊόν, τότε ο κανόνας αυτός έχει υποστήριξη 6% αν υποθέτουμε ότι έχουμε 100 εγγραφές αλλά και εμπιστοσύνη 60% (6 στους 10 πληρούν τη συνθήκη και την κατάληξη). Αν αυτές οι τιμές ξεπερνούν τα ελάχιστα αποδεκτά κατώφλια που έχουμε θέσει, τότε ο κανόνας γίνεται αποδεκτός. Παρατηρούμε ότι η εργασία έχει και μία σωστή προσέγγισή για πρακτικό μέρος.

Στην εργασία [7] έχουμε ένα survey για associative classification που περιγράφει τα βασικά πλεονεκτήματα της μεθόδου, για παράδειγμα υψηλή ακρίβεια μαζί με τα προβλήματα της όπως το πλήθος των κανόνων που δημιουργούνται μαζί με την δυσκολία επιλογής των χρήσιμων που καταλήγουμε σε ενσωμάτωση φίλτρων για καλύτερο mining.




Εικόνα 2. Βήματα για Associative Classification

Όπως μπορούμε να παρατηρήσουμε και από την Εικόνα 2 το σύστημα αρχικά έχει τα ruleitems που εμφανίζονται στο εκπαιδευτικό σύνολο. Έπειτα δημιουργείται κανόνας που προβλέπει την πιο συχνή κατηγορία και στη συνέχεια γίνεται το φιλτράρισμα για να έχουμε μόνο τα πιο χρήσιμα δεδομένα, στο τέλος αυτά τα δεδομένα εμφανίζονται στα νέα δεδομένα για να γίνει ακόμα καλύτερα και η πρόβλεψη με χρήση του Associative Classification.

Τέλος, έχουμε τελείως κάτι διαφορετικό στην μελέτη [8] που σημαίνει ότι δεν έχουμε απλά το associative classification αλλά χρησιμοποιείται πολλαπλούς κανόνες ταυτόχρονα και εφαρμόζει τεχνικές pruning, αυτή η νέα διαδικασία αυξάνει την ακρίβεια όσο και την υπολογιστική αποδοτικότητα.

### 2.3 Αποδοτικά Σύνολα Αντικειμένων

Για την εργασία "An efficient strategy for mining high-efficiency itemsets in quantitative databases" που θα βασιστούμε σε εργασίες που υποστηρίζουν για προηγούμενη μελέτη άλλα και εισάγει την έννοια της αποδοτικότητας, η οποία είναι εξελιγμένη μορφή αξιολόγησης itemsets.

Αρχικά, έχουμε το την εργασία [9] που βασίζεται σε utility αντί να εμφανίζεται μόνο στη συχνότητα εμφάνισης, προτείνει να λαμβάνονται υπόψη και οι ποσοτικές πληροφορίες έτσι ώστε να μπορούμε να εντοπίζουμε τα καλύτερα σύνολα. Η εργασία ήταν μία αρχική εισαγωγή σε High Utility Itemset Mining.

Στην συνέχεια για την εργασία [10] παρουσιάζεται η μέθοδος Efficient high-utility Itemset Mining που βασίζεται σε 2 τεχνικές, η μία είναι η αναλυτική ανάλυση utility upper bounds ώστε να περιορίζει τον χώρο αναζήτησης, και η άλλη είναι οι μηχανισμοί pruning για να αποφεύγει από άχρηστους κανόνες.

Τέλος, η εργασία [11] εισάγει το αλγόριθμο HEPMiner, έναν ειδικό αλγόριθμο για την εξόρυξη high-efficiency patterns, δηλαδή συνόλων που δεν έχουν απλώς υψηλή συνολική ωφέλεια, αλλά και υψηλό λόγο ωφέλειας προς κόστος. Η προσέγγιση αυτή προσφέρει πιο έξυπνα αποτελέσματα, που δίνουν μεγάλη αξία με λιγότερους πόρους.

Οι παραπάνω τρεις εργασίες βοήθησαν σημαντικά στην ανάπτυξη της παρούσας μεθόδου, καθώς έθεσαν τις βασικές αρχές της εξόρυξης συνόλων με υψηλή ωφέλεια, πρότειναν αποδοτικούς αλγορίθμους για να βρίσκονται γρήγορα τα πιο χρήσιμα σύνολα δεδομένων και εισήγαγαν την έννοια της αποδοτικότητας ως λόγου μεταξύ ωφέλειας και μεγέθους. Με βάση αυτές τις ιδέες, η παρούσα εργασία προτείνει μια νέα, πιο αποτελεσματική στρατηγική που στοχεύει να εντοπίσει τα πιο "αποδοτικά" σύνολα αντικειμένων με ταχύτερο και πιο έξυπνο τρόπο.

### 2.4 Χρήσιμα Σύνολα με Πολλαπλά Όρια

Η εργασία "New Approaches for Mining High Utility Itemsets with Multiple Utility Thresholds" που συνδυάζει χρησιμότητα, πολλαπλά utility thresholds, και τεχνικές επιτάχυνσης όπως παραλληλοποίηση.

Η μελέτη [12] εισάγει τον αλγόριθμο Two-phase, έναν από τους πρώτους για την εξόρυξη συνόλων στοιχείων υψηλής χρησιμότητας. Χρησιμοποιεί το άνω όριο Transaction Weight Utility για την περικοπή του χώρου αναζήτησης. Αυτή η τεχνική έγινε βάση για

όλους τους μεταγενέστερους αλγορίθμους HUIM και αποτελεί τη βάση για τις νέες τεχνικές του MHUI-MUT.

Στην εργασία [13] ο αλγόριθμος FHM είναι πρόδρομος του MHUI που βελτιώνει αυτή η εργασία. Εισάγει τη δομή Estimated Utility Cooccurrence Structure, έναν δισδιάστατο πίνακα για την πρώιμη περικοπή υποψηφίων με δύο στοιχεία. Ο MHUI βασίζεται στον FHM, κάνοντάς τον άμεσο πρόγονο του προτεινόμενου MHUI-MUT.

Στην εργασία [14] ο αλγόριθμος EFIM εισάγει τη sub-tree utility και την local utility, που υιοθετούνται στον MHUI-MUT. Χρησιμοποιεί επίσης την προβολή συναλλαγών και τη συγχώνευση παρόμοιων συναλλαγών για μείωση του χώρου αποθήκευσης και του χρόνου σάρωσης. Αυτές οι τεχνικές βελτιώνουν την απόδοση του προτεινόμενου αλγορίθμου.

Η εργασία [15] παρουσιάζει τον αλγόριθμο MHUI, το κύριο σημείο αναφοράς που βελτιώνει ο MHUI-MUT. Εισάγει το Suffix Minimum Utility threshold που χρησιμοποιεί το ελάχιστο κατώφλι των υποσχόμενων στοιχείων. Ο MHUI-MUT επεκτείνει αυτές τις ιδέες προτείνοντας το νέο Extension Minimum Utility threshold που είναι πιο αποτελεσματικό.

# 3 Προτεινόμενες Τεχνικές

Αρχικά, θα ξεκινήσουμε την προσσέγιση μας για τις τεχνικές που θα χρησιμοποιήσουμε στην θεωρητική περιγραφή αλλά και στην υλοποίηση και με τα πειράματα από την μελέτη “Association Rules Mining with Multiple Constraints” όπου είναι το πιο βασικό και θεωρητικό από τα 4 papers που έχουμε. Επίσης, εισάγει τα 4 concepts που θα είναι το frequent itemsets όπου είναι οι όροι που περιορίζουν τα itemsets που θα εξάγουμε, ώστε να είναι πιο σχετικοί για τον χρήστη. Το monotone constraint που σημαίνει ότι αν κάποιο σύνολο ικανοποιεί το περιορισμό που έχουμε, τότε όλα τα υπερσύνολα του επίσης θα τον ικανοποιούν, από την άλλη πλευρά το anti-monotone constraint δεν ικανοποιεί το περιορισμό, που σημαίνει τότε κανένα υπερσύνολο του δεν θα τον ικανοποιεί. Ουσιαστικά, έχουμε αναφερθεί και παραπάνω για αυτές τις ορολογίες όπου θα είναι και χρήσιμες για αυτό το section. Τέλος για αυτή την παράγραφο έχουμε και τα association rules όπου είναι κανόνες που εκφράζουν συσχετίσεις μεταξύ itemsets.

Στην συνέχεια θα συνεχίσουμε με το 2ο paper που θα είναι το “ Building an Associative Classifier with Multiple Minimum Supports”. Εφαρμόζει τα concepts των association rules σε classification. Μετά εισάγει την έννοια των Multiple Minimum Supports , που είναι μια εξέλιξη των constraints. Ουσιαστικά, είναι ένα paper που αρχίζει να μας βάζει στη λογική του classifier.

Σαν τρίτο paper θα έχουμε το “ An efficient strategy for mining high-efficiency itemsets in quantitative databases”. Έχει την λογική του efficiency που θα μας επεκτείνει το association rule mining σε πιο πραγματικά σενάρια. Είναι το κατάλληλο paper που θα δούμε τους όρους utility, efficiency, pruning με upper bounds.

Στο τέλος έχουμε το paper που είναι σχετικά με τα multiple utility thresholds. Περιέχει τα πιο τεχνικά concepts που συνδυάζει το utility mining, το multiple thresholds, pruning με DCP-friendly upper bounds αλλά και παράλληλη υλοποίηση. Ουσιαστικά μας μαθαίνει και για τις προηγούμενες προσεγγίσεις των paper που είχαμε και μας βάζει στο τελικό στάδιο για την έρευνα αυτή.

**Σειρά των Paper:**

1ο Paper: Association Rules Mining with Multiple Constraints

2ο Paper: Building an associative classifier with multiple minimum supports

3ο Paper: An efficient strategy for mining high-efficiency itemsets in quantitative databases

4ο Paper: New approaches for mining high utility itemsets with multiple utility thresholds

## 3.1 Θεωρητική περιγραφή

### 3.1.1 Ορολογίες Προβλήματος του 1ου Paper

Για το πρώτο paper που θα έχουμε την θεωρητική προσέγγιση, που αρχικά ξεκινάμε με τον ορισμό του προβλήματος που θέτει τα μαθηματικά θεμέλια για το πρόβλημα που περιέχουμε.

Έχουμε ένα itemset που είναι ο Items = $\{x_1, x_2, \ldots, x_n\}$ και αποτελούν τα διακριτά αντικείμενα, ένα σύνολο $X \subseteq$ Items όπου αν περιέχει k αντικείμενα σημαίνει ότι είναι k-itemset.

Μετά έχουμε μία συναλλαγή που είναι το ζεύγος <ID, X> . Που με το ID θα είναι ο μοναδικός αναγνωριστικός αριθμός συναλλαγής και το X το σύνολο αντικειμένων που αγοράστηκαν. Αλλά και μία βάση παρέχουμε για να βλέπουμε τις ενέργειες.

Συνεχίζουμε με το Support(X) που κατέχει το itemset X θα δηλώνεται και θα είναι ο αριθμός των συναλλαγών που περιέχουν το X. Δηλαδή κατά κάποιο τρόπο όλα θα γίνονται στο Support(X). Αυτή η μέθοδος έχει το κατώφλι δ όπου αν Support(X) ≥ δ τοτε θα θεωρήσουμε το X σαν frequent itemset.

Έπειτα το constraint θα είναι ένας κανόνας που λέει αν ένα itemset είναι «ενδιαφέρον» ή όχι και δηλώνεται ως συνάρτηση που περιέχει το True και False. Αυτό που προσπαθεί να καταφέρει το constraint είναι να εξετάσει την πληρότητα του itemset.

Βέβαια, όπως είχαμε αναφερθεί και ποιο πριν τα constraint αυτά είναι anti-monotone, monotone ή άλλη μία πιο περιορισμένη κατηγορία το convertible monotone που είναι οι περιπτώσεις που οι περιορισμοί γίνονται μονοτονικοί ή αντιμονοτονικοί αν τα αντικείμενα ταξινομηθούν κατάλληλα.

Για τους 2 άλλους όρους (anti-monotone και monotone) θα μπορούσαμε να δώσουμε τα παραδείγματα max(cost) ≤ min(price) και total(price) ≥ 100 αντίστοιχα.

Τέλος έχουμε το SATC(X) που είναι το σύνολο όλων των itemsets που ικανοποιούν τον περιορισμό δηλαδή όλα τα itemsets X πληρούν τον περιορισμό C.

Αυτό που μπορούμε να καταλάβουμε από αυτή την ενότητα είναι ότι το paper προσπαθεί να βρει τα frequent itemsets που ικανοποιούν δύο ταυτόχρονους περιορισμούς το C1 και το C2 που είναι το anti-monotone και το monotone αντίστοιχα.

### 3.1.2 Προτοινόμενη Θεωρητική Μέθοδο του 1ου Paper

Θα παρουσιάσουμε τον αλγόριθμο που προτίνεται, δηλαδή την μέθοδο που θα χρειαστούμε να χρησιμοποιήσουμε και στο πρακτικό κομμάτι του paper στην συνέχεια.

Θα έχουμε κάποια Dataset με χρήση την βάση και θα πρέπει να γίνει η ανάλυση. Οι πίνακες αποτελούνται από 2. Ο πρώτος πίνακας περιέχει τα TIDs μαζί με τα items ενώ ο δεύτερος Items, Cost και Price.

Όπου θα εφαρμόσουμε το monotone και anti-monotone δηλαδή C2 και C1.

| TID | Items |
|---|---|
| 1 | A, B, E |
| 2 | B,C |
| 3 | A,D,E |
| 4 | A,B,C,E |
| 5 | B,D |

**Εικόνα 3**. Παράδειγμα Βάσης Δεδομένων κατά Χρήση της Έρευνας

| Item | Cost | price |
|---|---|---|
| A | 30 | 45 |
| B | 35 | 40 |
| C | 50 | 60 |
| D | 25 | 40 |
| E | 20 | 45 |

**Εικόνα 4.** Πληροφορίες που θα χρειαστούμε σαν αντικείμενα

Εδώ οι εικόνες 3 και 4 χρησιμεύουν για να παρουσιαστεί ένα συγκεκριμένο παράδειγμα βάσης δεδομένων και να αποσαφηνιστεί πώς εφαρμόζεται ο προτεινόμενος αλγόριθμος εξόρυξης κανόνων συσχέτισης υπό περιορισμούς. Η εικόνα 3 περιέχει μια απλή βάση συναλλαγών. Σε αυτόν, κάθε γραμμή αντιπροσωπεύει μία συναλλαγή δηλαδή transaction με έναν TID και το σύνολο items που αγοράστηκαν. Για παράδειγμα, στη συναλλαγή με TID = 1 έχουν αγοραστεί τα αντικείμενα A, B και E. Η πληροφορία αυτή είναι η είσοδος του αλγορίθμου FP-Growth, ο οποίος χρησιμοποιείται ως βασικό πλαίσιο για την εξαγωγή frequent itemsets, δηλαδή συνόλων αντικειμένων που εμφανίζονται συχνά.

Έπειτα η εικόνα 4 συμπληρώνει την πληροφορία της εικόνας 3 προσθέτοντας χαρακτηριστικά για κάθε αντικείμενο δηλαδή, το **cost** και το **price**. Αυτά τα αριθμητικά γνωρίσματα είναι κρίσιμα, διότι αποτελούν τη βάση πάνω στην οποία εφαρμόζονται οι περιορισμοί του αλγορίθμου. Ο anti-monotone δηλώνει ότι για κάθε itemset που εξετάζεται, το μέγιστο κόστος των αντικειμένων του δεν πρέπει να ξεπερνά τη μικρότερη τιμή τους (max(cost) ≤ min(price)), ενώ ο monotone απαιτεί το συνολικό άθροισμα των τιμών να είναι τουλάχιστον 100 (total(price) ≥ 100).

Οι δύο πίνακες συνεργάζονται στον αλγόριθμο με τον τρόπο που από την εικόνα 3 προκύπτουν τα frequent itemsets μέσω μέτρησης support (σε πόσες συναλλαγές

εμφανίζεται κάθε σύνολο αντικειμένων). Στη συνέχεια, κάθε υποψήφιο itemset αξιολογείται βάσει των αριθμητικών constraints της εικόνας 3.

Ας δώσουμε ένα παράδειγμα για καλύτερη κατανόηση, αν εξετάσουμε το Itemset {A, B} γνωρίζουμε από τον Πίνακα 2 ότι το κόστος των A και B είναι 30 και 35 αντίστοιχα, ενώ οι τιμές τους είναι 45 και 40. Επομένως, max(cost) = 35 και min(price) = 40, άρα ο πρώτος περιορισμός ικανοποιείται. Όμως total(price) = 85, που είναι μικρότερο από το απαιτούμενο 100, άρα ο δεύτερος περιορισμός αποτυγχάνει με αποτέλεσμα το itemset να απορρίπτεται.

Τέλος για τους πίνακες, οι εικόνες αυτές μας δείχνουν πως λειτουργούν ως υπόβαθρο για την κατανόηση της προτεινόμενης μεθόδου. Η εικόνα 3 παρέχει τα δεδομένα των συναλλαγών για τον εντοπισμό συχνών συνδυασμών αντικειμένων από την άλλη πλευρά η εικόνα 4 παρέχει τις αριθμητικές παραμέτρους που επιτρέπουν στον αλγόριθμο να εφαρμόσει προηγμένα φίλτρα και να απορρίψει γρήγορα μη έγκυρα σύνολα. Αυτή η διαδικασία ενσωματώνεται στο μηχανισμό pruning του αλγορίθμου και επιτρέπει την αποδοτικότερη εξαγωγή σχετικών κανόνων συσχέτισης.

Αν πάμε τώρα βαθύτερα στον αλγόριθμο, θα παρουσιάζουμε την βασική λειτουργία του αλγορίθμου που δίνονται ορισμοί για τεχνικές έννοιες όπως το prefix μεταξύ itemsets, η max-a προβολή και οι conditional βάσεις δεδομένων. Αυτές οι έννοιες επιτρέπουν στον αλγόριθμο να λειτουργεί αναδρομικά περιορίζοντας το search space. Για να γίνει το pruning πιο αποδοτικό, αξιοποιούνται τέσσερα βασικά λήμματα που βοηθούν στο να αποφύγουμε τον έλεγχο περιττών συνδυασμών.

Lemma 1[4]. Let $\beta$ be the set of frequent items in $T|_a$ and $\gamma$ be a sub-set of the set of frequent items in $T|_a$. If we have confirmed $\Phi(a \cup \beta) = true$ in $T|_a$ where $\Phi$ is an anti-monotone constraint, we do not need to check $\Phi$ in $T|_{\{a\} \cup a}$ for each $a \in \beta$ because $(\{a\} \cup a \cup \gamma) \subseteq (\alpha \cup \beta)$ and thus $\Phi(\{a\} \cup a \cup \gamma)$ is certainly true.

**Εικόνα 5**. Lemma 1

Για το λήμμα 1:

Αν έχουμε ένα σύνολο frequent αντικειμένων που είναι το β και ένα υποσύνολό του που είναι το γ και αν έχουμε ήδη επιβεβαιώσει ότι το itemset α U β ικανοποιεί έναν αντιμονοτονικό περιορισμό Φ για παράδειγμα το max(cost) ≤ min(price, τότε δεν χρειάζεται να ξαναελέγξουμε τον ίδιο περιορισμό για τα itemsets που είναι επεκτάσεις όπως α U {a} U γ, για κάθε a που ανήκει στη β.

Επειδή τα νέα itemsets που προκύπτουν από την ένωση με a και γ είναι υποσύνολα ή ίσα με το αρχικό α U β. Και αφού ο περιορισμός είναι αντιμονοτονικός, αν ισχύει για το μεγάλο σύνολο τότε σίγουρα θα ισχύει και για τα μικρότερα.

Lemma 2[4]. Let $\gamma$ be a sub-set of the set of frequent items in $T|_{\{a\} \cup a}$, if we have confirmed $\Phi(a \cup \beta) = false$, where $\Phi$ is an anti-monotone constraint and a is an individual frequent item in $T|_a$, we do not need to generate $T|_{\{a\} \cup a}$ because $\{a\} \cup a \cup \gamma$ contains $\{a\} \cup a$ and thus $\Phi(\{a\} \cup a \cup \gamma)$ is certainly false.

**Εικόνα 6**. Lemma 2

Για το λήμμα 2:

Σε αυτή την περίπτωση ας πούμε αν το σύνολο αντικειμένων α U β και έχουμε ήδη διαπιστώσει ότι δεν ικανοποιεί έναν αντιμονοτονικό περιορισμό τότε δεν χρειάζεται να επεκτείνουμε αυτό το σύνολο με άλλα αντικείμενα. Ο λόγος είναι ότι στους anti-monotone περιορισμούς, αν ένα σύνολο αποτύχει τότε όλα τα υπερσύνολά του αποτυγχάνουν κι αυτά. Δηλαδή κατά κάποιο τρόπο με αυτό το λήμμα γλυτώνουμε χρόνο και χώρο.

Lemma 3. Let $\beta$ be the set of frequent items in $T|_a$ and $\gamma$ be a sub-set of the set of frequent items in $T|_a$ If we have confirmed $\Phi(a \cup \beta) = flase$ in $T|_a$ where $\Phi$ is a monotone constraint, we do not need to check $\Phi$ in $T|_{\{a\} \cup a}$ for each $a \in \beta$ because $(\{a\} \cup a \cup \gamma) \subseteq (\alpha \cup \beta)$ and thus $\Phi(\{a\} \cup a \cup \gamma)$ is certainly false.

**Εικόνα 7.** Lemma 3

Για το λήμμα 3:

Στο λήμμα 3 έχουμε το σύνολο αντικειμένων α U β και διαπιστώσουμε ότι δεν ικανοποιεί έναν μονοτονικό περιορισμό τότε δεν χρειάζεται να ελέγξουμε τα μικρότερα υποσύνολα του γιατί και αυτά σίγουρα δεν θα τον ικανοποιούν. Αυτό συμβαίνει επειδή στους monotone περιορισμούς αν ένα σύνολο αποτύχει τότε όλα και τα υποσύνολα αποτυγχάνουν. Πρέπει να προσέξουμε ότι σε αυτό το λήμμα μιλάμε για το monotone.

Lemma 4. Let $\gamma$ be a sub-set of the set of frequent items in $T|_{\{a\} \cup a}$, If we have confirmed $\Phi(a \cup \beta) = true$, where $\Phi$ is a monotone constraint and a is an individual frequent item in $T|_a$, we do not need to generate $T|_{\{a\} \cup a}$ because $\{a\} \cup a \cup \gamma$ contains $\{a\} \cup a$ and thus $\Phi(\{a\} \cup a \cup \gamma)$ is certainly true.

**Εικόνα 8.** Lemma 4

Για το λήμμα 4:

Τέλος, αν αυτή την φορά έχουμε ένα σύνολο α U β που ήδη ικανοποιεί έναν μονοτονικό περιορισμό τότε δεν χρειάζεται να ελέγξουμε τα μεγαλύτερα σύνολα που το περιέχουν γιατί είναι σίγουρο ότι θα τον ικανοποιούν κι αυτά.

Με αυτά τα λήμματα ουσιαστικά έχουμε ορίσει τα περιθώρια για την πειραματική προσέγγιση που θα έχουμε στην συνέχεια, αλλά επίσης έχουμε καθορίσει τους κανόνες έτσι ώστε να καταλαβαίνουμε και την ιδεολογία της μέθοδος.

### 3.1.3 Ορισμός Προβλήματος για το 2ο Paper

Αρχικά, έχουμε το θεωριτικό κομμάτι για τον αλγόριθμο που θα χρησιμοποιήσουμε που είναι ο MMSCBA. Το πρόβλημα ξεκινά από την ανάγκη να φτιάξουμε έναν ταξινομητή που να βασίζεται σε κανόνες συσχέτισης με μεγαλύτερη ευελιξία από τις παραδοσιακές μεθόδους.

Συγκεκριμένα έχουμε την εισαγωγή του Minimum Item Supports ώστε κάθε αντικείμενο να έχει το δικό του όριο συχνότητας και να μην αποκλείονται σημαντικοί κανόνες μόνο και μόνο επειδή περιλαμβάνουν τα σπάνια αντικείμενα.

| Attribute-name | Attribute-value | Item |
|---|---|---|
| *a* | {1, 2, 3} | (*a*, 1) (*a*, 2) (*a*, 3) |
| *b* | {1, 2} | (*b*,1) (*b*, 2) |
| *c* | {1, 2, 3} | (*c*,1) (*c*, 2) (*c*, 3) |
| *d* | {1, 2} | (*d*, 1) (*d*, 2) |
| *e* | {1, 2} | (*e*, 1) (*e*, 2) |

**Εικόνα 9**. Τα attributes με values και ονομασίες

Η **εικόνα 9** παρουσιάζει τα attributes που υπάρχουν στη βάση δεδομένων μαζί με τις δυνατές τιμές τους.

Για παράδειγμα το χαρακτηριστικό a μπορεί να πάρει τιμές 1, 2 ή 3, ενώ το b μπορεί να πάρει μόνο 1 ή 2. Στη στήλη Item βλέπουμε την αναπαράσταση κάθε πιθανής τιμής ως αντικείμενο. Έτσι, το (a, 1) είναι ένα item, που σημαίνει ότι το a έχει την τιμή 1. Με αυτό τον τρόπο, κάθε γραμμή της βάσης δεδομένων θα αναπαρίσταται ως ένα **σύνολο από items**, όπου κάθε item εκφράζει μία συγκεκριμένη τιμή ενός χαρακτηριστικού.

**Table 2 The sample database *D***

| *sid* | Database |
|---|---|
| 1 | {(*a*, 1)(*b*, 1)(*d*, 2)(*e*, 1), $y_1$} |
| 2 | {(*a*, 1)(*b*, 2)(*c*, 3)(*d*, 2)(*e*, 1), $y_2$} |
| 3 | {(*a*, 3)(*b*, 2)(*c*, 3)(*d*, 1)(*e*, 1), $y_2$} |
| 4 | {(*a*, 1)(*b*, 1)(*c*, 1)(*d*, 2)(*e*, 1), $y_1$} |
| 5 | {(*a*, 1)(*c*, 3)(*d*, 2)(*e*, 1), $y_1$} |

**Εικόνα 10**. Δείγμα βάσης δεδομένων

Έπειτα έχουμε την εικόνα 10 που δείχνει ένα μικρό δείγμα της βάσης δεδομένων D, η οποία αποτελείται από πέντε παραδείγματα η στήλη SID. Κάθε παράδειγμα είναι ένα σύνολο items μαζί με μια ετικέτα κλάσης στο τέλος.

Για παράδειγμα, η πρώτη γραμμή περιέχει τα items (a,1)(b,1)(d,2)(e,1) και ανήκει στην κλάση y1. Αυτό σημαίνει ότι σε αυτό το παράδειγμα το a=1, b=1, d=2, e=1, και το output είναι y1. Με παρόμοιο τρόπο, οι υπόλοιπες εγγραφές έχουν διαφορετικούς συνδυασμούς χαρακτηριστικών και ανήκουν είτε στην κλάση y1 είτε y2.

Η χρήση αυτών των πινάκων εξυπηρετεί στην κατανόηση του πλαισίου της ταξινόμησης. Ο στόχος είναι να αναγνωρίσουμε ποια items μπορούν να συνδυαστούν για να δημιουργήσουν κανόνες της μορφής X → y, δηλαδή το όρο «αν ισχύει το σύνολο X, τότε η κλάση είναι y».

Ένα άλλο παράδειγμα θα ήταν αν το (a,1)(b,1) οδηγεί συνήθως στην κλάση y1, τότε αυτό είναι ένας υποψήφιος rule-item. Χάρη στη δομή των πινάκων μπορούμε να ελέγξουμε πόσο συχνά εμφανίζονται τέτοιοι συνδυασμοί, και να τους αξιολογήσουμε με βάση την ελάχιστη υποστήριξη ανά αντικείμενο (MIS) και το confidence. Με αυτό τον τρόπο θα μπορούμε να εξετάσουμε και το πρακτικό μέρος της εργασίας όπου θα βασιστούμε σε αυτά.

Ουσιαστικά, δείχνουν πώς τα attributes γίνονται items, πώς συνδυάζονται σε συναλλαγές, και πώς τελικά οδηγούν σε κανόνες που χρησιμοποιούνται για την ταξινόμηση.

### 3.1.4 Ο Αλγόριθμος MMSCBA του 2ου Paper

Ο αλγόριθμος MMSCBA ο οποίος είναι η καρδιά της προτεινόμενης μεθόδου. Σκοπός του MMSCBA είναι να δημιουργήσει έναν rule-based classifier που να μπορεί να διατηρεί και να αξιοποιεί κανόνες που περιλαμβάνουν σπάνια αλλά σημαντικά χαρακτηριστικά τα οποία θα χάνονταν με ένα ενιαίο όριο υποστήριξης. Για να το πετύχει αυτό, ο αλγόριθμος χρησιμοποιεί την έννοια των Minimum Item Support δηλαδή ξεχωριστό support threshold για κάθε αντικείμενο.

Το πρώτο βασικό βήμα του MMSCBA είναι η εξαγωγή rule-items από τη βάση δεδομένων. Ένας rule-item έχει τη μορφή X → c όπου X είναι ένα σύνολο αντικειμένων (όπως (a,1)(b,2)) και c είναι η κλάση (όπως y1).

Σε αντίθεση με τις παραδοσιακές μεθόδους εξόρυξης κανόνων, ο MMSCBA ελέγχει αν ο κανόνας είναι αποδεκτός όχι με βάση ένα κοινό support threshold, αλλά με βάση το μέγιστο MIS μεταξύ των αντικειμένων του X. Δηλαδή κάθε rule πρέπει να εμφανίζεται στη βάση δεδομένων τουλάχιστον τόσες φορές όσες απαιτεί το πιο αυστηρό από τα αντικείμενα του. Αυτή η ευελιξία επιτρέπει στον αλγόριθμο να κρατήσει και κανόνες που περιλαμβάνουν σπάνια αντικείμενα τα οποία όμως μπορεί να είναι πολύ διακριτικά για κάποια κλάση.

Αφού εξορυχθούν οι υποψήφιοι κανόνες συνεχίζουμε με το στάδιο του φιλτραρίσματος και της ταξινόμησης. Στο σημείο αυτό κάθε κανόνας αξιολογείται ως προς το confidence του και κρατούνται μόνο όσοι ξεπερνούν ένα προκαθορισμένο κατώφλι. Εκτός από το confidence ο αλγόριθμος υποστηρίζει και κριτήρια ποιότητας για να διαλέξει ανάμεσα σε πολλούς κανόνες όπως το Maximum Likelihood, η Laplace, η μέθοδος $\chi^2$. Αυτά τα κριτήρια επιτρέπουν την κατάταξη των κανόνων και την επιλογή των πιο χρήσιμων για το τελικό μοντέλο.

Το τελικό βήμα του MMSCBA είναι η κατασκευή του ταξινομητή. Ο ταξινομητής αποτελείται από τους επιλεγμένους κανόνες οι οποίοι εφαρμόζονται με σειρά προτεραιότητας: όταν ένα νέο παράδειγμα εισέρχεται για ταξινόμηση. Επίσης, αναζητά ποιοι κανόνες ταιριάζουν σε αυτό και επιστρέφει την κλάση του πρώτου έγκυρου κανόνα που ταιριάζει. Εάν δεν ταιριάζει κανένας κανόνας τότε χρησιμοποιείται ένας default κανόνας, ο οποίος επιλέγεται με βάση την πιο συχνή κλάση στα δεδομένα εκπαίδευσης.

Στο διάγραμμα ροής του MMSCBA, το οποίο περιγράφει γραφικά τη διαδικασία βήμα προς βήμα. Ξεκινά από την είσοδο των δεδομένων και περνά από τις φάσεις εξόρυξης κανόνων με MIS που υπολογίζει το support και confidence. Στην συνέχεια επιλέγει τους κανόνες βάση ποιότητας δημιουργίας του ταξινομητή και για πρόβλεψη κλάσης. Αυτό το flowchart δείχνει με απλό τρόπο την αλγοριθμική ροή και είναι χρήσιμο για την κατανόηση της λογικής του μοντέλου. Αξίζει να σημειωθεί ότι το MMSCBA δεν προτείνει έναν απλό τροποποιημένο ταξινομητή αλλά ένα πλήρες πλαίσιο ενσωμάτωσης MMS σε ταξινόμηση.

### 3.1.5 Ορισμός Προβλήματος του 3ου paper

Όπως έχουμε εφαρμόσει και σε προηγούμενες εργασίες και τώρα θα προσπαθήσουμε να καταλάβουμε τον ορισμό που διαθέτουμε έτσι ώστε στην συνέχεια να έχουμε την δυνατότητα να μπούμε στο βάθος του προβλήματος.

Διαθέτουμε έναν μαθηματικό στόχο που αρχικά θα στοχεύουμε την αποδοτικότητα ενός συνόλου itemset μαζί με τα κέρδη αλλά και το HEI που είναι το High-Efficiency Itemset μαζί με τα δεδομένα που απαιτούνται.

Όπως είχαμε αναφερθεί και σε προηγούμενη εργασία και εδώ έχουμε μία βάση δεδομένων που περιλαμβάνει transactions που κάθε συναλλαγή περιέχει items και ποσότητες. Μετέπειτα έχουμε τα κέρδη ανά μονάδα και κάτι διαφορετικό την επένδυση ανά μονάδα.

Οι βασικοί ορισμοί και υπολογισμοί που εισάγονται στην ενότητα αυτή αφορούν την κατανόηση του τρόπου με τον οποίο υπολογίζεται η αποδοτικότητα ενός συνόλου ειδών μέσα σε μια ποσοτική βάση δεδομένων. Κάθε συναλλαγή περιλαμβάνει είδη και τις αντίστοιχες ποσότητές τους ενώ για κάθε είδος είναι γνωστό τόσο το κέρδος ανά μονάδα όσο και το κόστος επένδυσης ανά μονάδα. Η ποσότητα ενός είδους σε μια συναλλαγή συμβολίζεται κατάλληλα, το κέρδος του υπολογίζεται ως το γινόμενο του κέρδους ανά μονάδα με την ποσότητα ενώ η επένδυση που είναι και η διαφορά που έχουμε υπολογίζεται ως το γινόμενο του κόστους επένδυσης ανά μονάδα με την ποσότητα. Το συνολικό κέρδος ενός συνόλου ειδών στη βάση δεδομένων είναι το άθροισμα των κερδών του σε όλες τις συναλλαγές όπου περιέχεται και αντίστοιχα η συνολική επένδυση είναι το άθροισμα των επιμέρους επενδύσεων των ειδών που το αποτελούν.

Η αποδοτικότητα ενός συνόλου ειδών ορίζεται ως το πηλίκο του συνολικού κέρδους προς τη συνολική επένδυση. Ένα σύνολο ειδών θεωρείται υψηλής αποδοτικότητας όταν η αποδοτικότητά του ξεπερνά ή ισούται με ένα κατώφλι που ορίζει ο χρήστης.

Για καλύτερη κατανόηση αν δώσουμε ένα παράδειγμα:

Έστω ότι θα εξετάσουμε το σύνολο ειδών X = (a,b), δηλαδή ένα itemset που περιέχει τα είδη a και b.

Στο **πρώτο βήμα** έχουμε την συνολική επένδυση (inve):

Γνωρίζουμε από το πίνακα ότι το είδος α έχει συνολική επένδυση 66 και το b την συνολική επένδυση 72, συνολικά 138.

Στο **δεύτερο βήμα** που είναι κέρδος στις συναλλαγές:

Προσπαθούμε να κατανοήσουμε σε ποιες συναλλαγές εμφανίζεται το itemset(a,b). Που είναι η συναλλαγή T1 και T6. Με κέρδη 10 και 7 αντίστοιχα και συνολικά 17.

Σαν **τρίτο βήμα** τον υπολογισμό της αποδοτικότητας (ef):

Που είναι το συνολικό κέρδος/ συνολική επένδυση = 17/138 ≈ 0,123.

Σαν **τελευταίο βήμα** είναι η σύγκριση με το κατώφλι δ:

Αν ο χρήστης έχει θέσει το κατώφλι αποδοτικότητας δ σε 0,3 τότε→ το ef(X) = 0,123 < 0,3

Αυτό το παράδειγμα δείχνει πώς ακόμα κι αν ένα σύνολο ειδών έχει σχετικά καλό κέρδος μπορεί να μην θεωρείται αποδοτικό αν έχει μεγάλο κόστος επένδυσης. Στόχος του HEIM είναι να εντοπίζει εκείνα τα σύνολα που προσφέρουν μεγαλύτερη αξία ανά ευρώ επένδυσης, και όχι απλώς αυτά που πουλάνε ή κερδίζουν περισσότερο. Βέβαια έχουμε και το παράδειγμα της θετικής προσεγγίσεις αυτού του προβλήματος.

Ο τυπικός ορισμός του προβλήματος HEIM περιγράφει έναν στόχο που είναι να εντοπιστούν όλα τα σύνολα ειδών μέσα σε μια ποσοτική βάση δεδομένων τα οποία προσφέρουν υψηλή αποδοτικότητα, δηλαδή έχουν μεγάλο λόγο κέρδους προς κόστος επένδυσης. Για να γίνει αυτό, απαιτούνται τρία είδη πληροφορίας: οι συναλλαγές με τις ποσότητες των ειδών, οι τιμές του κέρδους ανά μονάδα για κάθε είδος, και οι τιμές της επένδυσης ανά μονάδα για κάθε είδος. Που τα περιγράψαμε προηγουμένως.

### 3.1.6 Προτεινόμενος Αλγόριθμος 3ου Paper

Ο προτεινόμενος αλγόριθμος MHEI είναι για να βελτιώσει την ταχύτητα και την αποδοτικότητά στην εξόρυξη High Efficiency Itemsets από της βάσεις δεδομένων. Που για να μπορούμε να καταφέρουμε αυτό χρησιμοποιείται τεχνικές που θα μειώνουν τον αριθμό των υπολογισμών και τις σαρώσεις για την βάση έχοντας υπόψη μόνο τα σημαντικά σύνολα δεδομένων.

Αρχικά, η βάση αναλύεται για να υπολογιστεί το Transaction Weight Utility κάθε είδους το οποίο ουσιαστικά αντιπροσωπεύει το συνολικό κέρδος των συναλλαγών στις οποίες συμμετέχει. Με βάση αυτό το μέγεθος, τα είδη ταξινομούνται, ώστε να υπολογίζονται πρώτα εκείνα με μεγαλύτερη δυναμική. Χρησιμοποιείται μια δομή δέντρου (Set Enumeration Tree) για να οργανωθεί ο χώρος αναζήτησης των συνδυασμών ειδών αλλά όχι όλα τα μονοπάτια του δέντρου εξετάζονται. Αντίθετα, εφαρμόζεται ένα έξυπνο προοδευτικό φιλτράρισμα μέσω μαθηματικών άνω φραγμάτων (upper bounds) που επιτρέπουν την πρόωρη αποκοπή μη αποδοτικών υποσυνόλων.

Δύο βασικά άνω φράγματα είναι το Local Efficiency και το Subtree Efficiency. Αυτά εκτιμούν κατά πόσο έχει νόημα να επεκτείνουμε ένα itemset με κάποιο νέο είδος. Εάν κάποια επέκταση έχει μικρότερη εκτιμώμενη αποδοτικότητα από το κατώφλι δ, τότε αυτή και όλες οι μελλοντικές της επεκτάσεις κόβονται. Για ακόμη πιο ακριβές φιλτράρισμα.

Ο αλγόριθμος προτείνει και τις αυστηρότερες εκδοχές όπως το Stricter Local Efficiency και Stricter Subtree Efficiency που υπολογίζουν επίσης την ελάχιστη πιθανή επένδυση στις μελλοντικές επεκτάσεις.

Ο MHEI αποφεύγει τις επαναλαμβανόμενες σαρώσεις της βάσης χρησιμοποιώντας προβολή συναλλαγών που κάθε φορά που εξετάζει ένα itemset, δημιουργεί υποσύνολα των συναλλαγών που περιέχουν μόνο τα επεκτάσιμα είδη. Αν συναλλαγές έχουν ίδια μορφή συγχωνεύονται, ώστε να μειωθεί η αποθήκευση και οι υπολογισμοί.

Τέλος η αναδρομική διαδικασία Explore(X) χρησιμοποιείται για να εξερευνήσει τα υποψήφια σύνολα. Για κάθε promising itemset X ο αλγόριθμος υπολογίζει αν πληροί την αποδοτικότητα $ef(X) \geq \delta$ και συνεχίζει την επέκταση του μόνο με είδη που δεν έχουν απορριφθεί από τα αυστηρά άνω φράγματα.

**Για παράδειγμα**:

Ο αλγόριθμος εξετάζει αν αξίζει να επεκτείνει το σύνολο {g} με άλλα είδη όπως a και b. Για την επέκταση με b η πραγματική αποδοτικότητα είναι χαμηλή (0.116) και τα άνω φράγματα slef και ssef είναι κι αυτά κάτω από το όριο (0.5). Άρα, το σύνολο {g, b} απορρίπτεται χωρίς περαιτέρω υπολογισμούς. Εν τέλη, ο αλγόριθμος γλιτώνει χρόνο εστιάζοντας μόνο σε αποδοτικές επεκτάσεις.

### 3.1.7 Προκαταρτικά 4ου Paper

Όπως έχουμε παρουσιάσει και στην προηγούμενη εργασία για την θεωρητική προσέγγιση και εδώ έχουμε προκαταρτικά με πολλαπλά κατώφλια χρησιμότητας.

Έχουμε μια βάση δεδομένων συναλλαγών όπου κάθε συναλλαγή περιλαμβάνει ένα σύνολο αντικειμένων μαζί με τις αντίστοιχες ποσότητες. Δηλαδή, κάθε αντικείμενο εμφανίζεται με μια συγκεκριμένη ποσότητα εντός της συναλλαγής.

Για κάθε αντικείμενο υπάρχει μια καθορισμένη τιμή χρησιμότητας η οποία αντιπροσωπεύει το κέρδος ανά μονάδα. Η χρησιμότητα ενός αντικειμένου μέσα σε μια συναλλαγή υπολογίζεται ως το γινόμενο του κέρδους του επί την ποσότητα στην οποία εμφανίζεται. Η χρησιμότητα ενός συνόλου αντικειμένων σε μια συναλλαγή προκύπτει ως το συνολικό άθροισμα των χρησιμοτήτων των μεμονωμένων αντικειμένων του συνόλου που συμμετέχουν στη συγκεκριμένη συναλλαγή.

Επιπλέον, κάθε αντικείμενο συνοδεύεται από ένα ελάχιστο κατώφλι χρησιμότητας το οποίο υποδεικνύει το κατώτερο αποδεκτό επίπεδο χρησιμότητας που πρέπει να πληροί ώστε να θεωρείται σημαντικό. Αν έχουμε ένα σύνολο αντικειμένων το κατώφλι χρησιμότητας του συνόλου προκύπτει από το μικρότερο κατώφλι των αντικειμένων που το αποτελούν.

Ο στόχος του προβλήματος είναι να εντοπιστούν όλα τα σύνολα αντικειμένων των οποίων η συνολική χρησιμότητα σε όλες τις συναλλαγές της βάσης είναι τουλάχιστον ίση με το αντίστοιχο ελάχιστο κατώφλι τους. Αυτά τα σύνολα χαρακτηρίζονται ως σύνολα αντικειμένων υψηλής χρησιμότητας.

Η ενότητα επίσης εισάγει επιπρόσθετες έννοιες που διευκολύνουν την αποδοτική αναζήτηση, όπως η συνολική χρησιμότητα κάθε συναλλαγής με χρησιμότητα συναλλαγής που αποτελεί ένα ανώτερο όριο της πραγματικής χρησιμότητας καθώς και η ταξινόμηση των αντικειμένων με βάση αυτό το μέγεθος. Αυτά τα βοηθητικά μέτρα χρησιμοποιούνται σε τεχνικές αποκοπής του χώρου αναζήτησης ώστε να μειωθεί η υπολογιστική πολυπλοκότητα κατά την εξόρυξη.

### 3.1.8 Προτεινόμενος Αλγόριθμος 4ου Paper

Αυτή την φορά θα προσπαθήσουμε να εξηγήσουμε τον αλγόριθμο MHUI-MUT που έχει διαφορετικό κατώφλι χρησιμότητας. Η καινοτομία του προτεινόμενου αλγορίθμου είναι ότι χρησιμοποιεί πιο έξυπνα φίλτρα δηλαδή τα ανώτερα όρια ή αλλιώς upper bounds για να μειώσει το πόσα δεδομένα χρειάζεται να ελέγξει. Επίσης, εισάγει έναν νέο τρόπο να αποφασίζει αν ένα σύνολο προϊόντων αξίζει να εξεταστεί, τον οποίο ονομάζει EMU. Αυτό το νέο κατώφλι είναι πιο ακριβές και βοηθά να απορρίπτονται άχρηστες επιλογές από νωρίς.

Ας εξηγήσουμε τα ορίσματα που θα μας είναι χρήσιμες:

**Transaction Utility (TU):** Το συνολικό κέρδος μιας συναλλαγής.

**Transaction Weighted Utility (TWU):** Πόσο σημαντικός είναι ένας συνδυασμός προϊόντων στη βάση.

**Minimum Item Utility (MU):** Ελάχιστο κέρδος που πρέπει να έχει κάθε προϊόν.

**Minimum Utility of an Itemset (MIU):** Ελάχιστο αποδεκτό κέρδος για έναν συνδυασμό προϊόντων.

**Suffix Minimum Utility (SMU):** Κόβει συνδυασμούς που δεν έχουν μέλλον, ακόμα κι αν επεκταθούν.

**Local Utility (lu):** Το μέγιστο κέρδος που μπορεί να προκύψει αν προστεθεί ένα προϊόν.

**Sub-tree Utility (su):** Εναλλακτικό όριο για να ελέγξουμε την αξία μιας επέκτασης.

**Extension Minimum Utility (EMU):** Έξυπνο φίλτρο για να απορρίπτουμε άχρηστες επεκτάσεις.

**P-items:** Τα προϊόντα που αξίζει να προστεθούν άμεσα.

**S-items:** Τα προϊόντα που μπορούν να εξεταστούν στα επόμενα βήματα.

**Projection:** Κρατάμε μόνο τα χρήσιμα δεδομένα για κάθε βήμα.

**Merging Transactions:** Συνδυάζουμε παρόμοιες συναλλαγές για εξοικονόμηση πόρων.

Στην συνέχεια έχουμε τον αλγόριθμο MHUI-MUT που θα περιγράψουμε βήμα βήμα πως υλοποιείται.

**Βήμα 1 – Υπολογισμός TWU:**
Μετράμε πόσο "σημαντικό" είναι κάθε προϊόν και τα βάζουμε σε σειρά από το λιγότερο στο πιο σημαντικό.

**Βήμα 2 – Φιλτράρισμα:**
Αφαιρούμε όσα προϊόντα δεν έχουν αρκετό κέρδος και απλοποιούμε τις συναλλαγές.

**Βήμα 3 – Δημιουργία P-items:**
Βρίσκουμε ποια προϊόντα αξίζει να χρησιμοποιήσουμε πρώτα για συνδυασμούς.

**Βήμα 4 – Αναδρομική Αναζήτηση:**
Ξεκινάμε να χτίζουμε συνδυασμούς βήμα-βήμα, κρατώντας μόνο όσους έχουν αρκετό κέρδος.

Τέλος, κάθε φορά που βρίσκουμε νέο συνδυασμό:
Τον ελέγχουμε αν περνάει το κατώφλι MIU μετά κοιτάμε μόνο τις χρήσιμες συναλλαγές που χρησιμοποιούμε το EMU για να κόψουμε τους άχρηστους συνδυασμούς

## 3.2 Υλοποίηση-Πειράματα

### 3.2.1 Πειραματικά Αποτελέσματα Υλοποίησης του 1ου Paper

Σε αυτό το section των πειραματικών αποτελεσμάτων θα μελετήσουμε την αποδοτικότητα του προτεινόμενου αλγορίθμου σε σύγκριση με την ενισχυμένη εκδοχή του FP-Growth που ονομάζεται FP-Growth+.

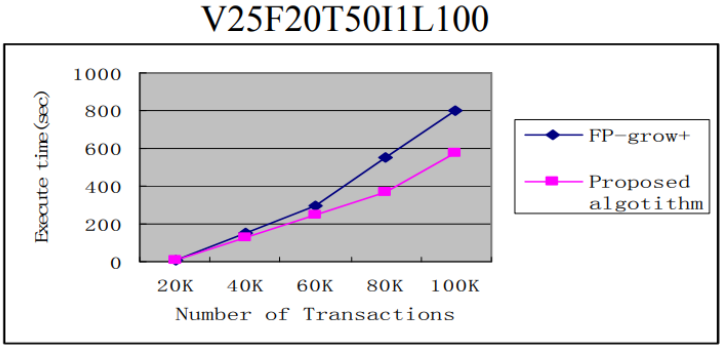
Στόχος είναι να εξετάσουμε αν ο νέος αλγόριθμος που χρησιμοποιεί ταυτόχρονα μονοτονικούς και αντιμονοτονικούς περιορισμούς μπορεί να επιταχύνει την εξόρυξη κανόνων σε μεγάλες βάσεις δεδομένων.

Τα πειράματα πραγματοποιήθηκαν σε υπολογιστή με επεξεργαστή Pentium IV στα 3.2GHz και 2MB μνήμη. Ο αλγόριθμος υλοποιήθηκε σε C++ και δοκιμάστηκε σε συνθετικά δεδομένα με παραμέτρους που προσομοιώνουν πραγματικά σενάρια. Το dataset που χρησιμοποιήθηκε περιλάμβανε 50k συναλλαγές 1k μοναδικά αντικείμενα και 100 πιθανά μέγιστα σύνολα.

Έχουμε μετρήσει τον χρόνο εκτέλεσης σε διάφορες συνθήκες. Πρώτα δοκιμάσαμε πώς αλλάζει ο χρόνος όταν αυξάνεται το πλήθος των συναλλαγών. Διαπιστώθηκε ότι ο προτεινόμενος αλγόριθμος ήταν σταθερά πιο γρήγορος από το FP-Growth+ και ιδιαίτερα αποδοτικός σε μεγάλα σύνολα δεδομένων.

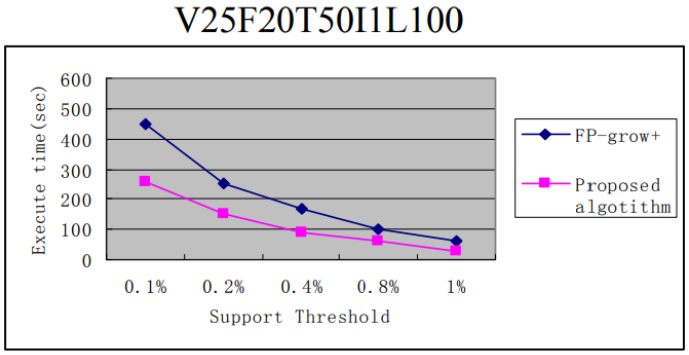
Στη συνέχεια, εξετάζουμε τον χρόνο εκτέλεσης σε σχέση με το όριο υποστήριξης support threshold. Όσο το όριο μειώνεται τόσο περισσότερα frequent itemsets δημιουργούνται άρα αυξάνεται ο χρόνος. Παρόλα αυτά ο προτεινόμενος αλγόριθμος συνέχισε να ξεπερνά σε ταχύτητα το FP-Growth+.

Συνολικά τα πειραματικά αποτελέσματα δείχνουν ότι η χρήση διπλών περιορισμών συνδυαστικά με έξυπνη περικοπή του search space κάνει τον αλγόριθμο πιο αποδοτικό και ικανό να διαχειριστεί μεγάλα δεδομένα με καλύτερη απόδοση από προηγούμενες μεθόδους.




**Εικόνα 11**. Καθοδήγηση για το πόσο ο χρόνος αυξάνεται

Στην εικόνα 11 παρατηρούμε πως η καμπύλη του προτεινόμενου αλγορίθμου είναι κάτω από εκείνη του FP-Growth+ σε όλες τις περιπτώσεις. Αυτό σημαίνει ότι όσο αυξάνεται ο όγκος των δεδομένων ο προτεινόμενος αλγόριθμος παραμένει ταχύτερος και κλιμακώνεται καλύτερα. Με άλλα λόγια είναι πιο αποδοτικός σε μεγάλες βάσεις.




**Εικόνα 10**. Επίδειξη επιρροής του χρόνου από το Support

Όσο χαμηλότερο είναι το όριο υποστήριξης τόσο περισσότερα frequent itemsets δημιουργούνται άρα αυξάνεται ο υπολογιστικός φόρτος.

Όπως και στο προηγούμενο γράφημα η καμπύλη του προτεινόμενου αλγορίθμου είναι πάντα χαμηλότερη δείχνοντας ότι ακόμη και όταν υπάρχουν πολλές υποψήφιες συχνές ομάδες ο αλγόριθμος συνεχίζει να είναι ταχύτερος από τον FP-Growth+.

### 3.2.2 Πειραματική Αξιολόγηση 2ου Paper

Σε αυτή την υποενότητα, θα έχουμε το στόχο να αποδείξουμε την αποτελεσματικότητα του αλγορίθμου MMSCBA. Τα πειράματα μας βασίζονται σε 6 διαφορετικά datasets από UCI repository, τα οποία επιλέχθηκαν ώστε να καλύπτουν ποικιλία σε μέγεθος και αριθμό κλάσεων. Τα σύνολα δεδομένων αποτελούνται από Breast Cancer Wisconsin, Blood Samples, Mushroom 2, Car, Credit και Segment.

Στην συνέχεια, έχουμε κάποια selection criteria τα οποία ουσιαστικά αποτελούνται όπως είχαμε αναφερθεί και σε προηγούμενη ενότητα (θεωρητική) από Maximum Likelihood, Laplace, $\chi^2$και Scoring Function που είναι η εσωρετική συνάρτηση του αλγορίθμου που αξιολογεί τους κανόνες.

Εκτός από την σύγκριση διαφορετικών rule selection methods που έχουμε τα πειράματα προσπαθούν να μας δείξουν πως επηρεάζεται η απόδοση του μοντέλου από τις παραμέτρους minsup και sigma που επηρεάζουν τα thresholds. Είναι μία σημαντική προσέγγιση για επίδειξη της βέλτιστης συμπεριφοράς για κάθε dataset.

Με τους πίνακες που παρέχουμε σε αυτήν την ενότητα ουσιαστικά μπορούμε να κάνουμε την ανάλυση με διαφορετικές όψεις ώστε να έχουμε και μία καλύτερη εικόνα.

Αν αναλύσουμε το πίνακα 3 που παρέχει τα λεπτομερή UCI datasets για την μελέτη καταλαβαίνουμε ότι ο αλγόριθμος έχει σχεδιαστεί για σενάρια με μεγάλη ποικιλομορφία.

Συγκεκριμένα έχουμε γνωστά dataset τα οποία χρησιμοποιούνται συχνά για benchmarking αλγορίθμων ταξινόμησης, δηλαδή για μέτρηση και αξιολόγηση των δεδομένων με μεγάλο όγκο δεδομένων. Μετά έχουμε τα attributes που κατά κάποιο τρόπο καταλαβαίνουμε την μεθοδολογία των δεδομένων μαζί με το σύνολο των δεδομένων. Αναλόγως τα attributes καταλαβαίνουμε πόσο περίπλοκα είναι τα δεδομένα που έχουμε σε χρήση μαζί με τις κλάσεις που όσο περισσότερες κλάσεις έχουμε, τόσο

πιο δύσκολη γίνεται η ταξινόμηση. Τέλος, το πιο σημαντικό σημείο είναι η στήλη rare item problem που είναι και ο λόγος όλων των εργασιών που μελετάμε. Προσπαθούμε να μην απορρίπτουμε τα σπάνια γεγονότα αμέσως με τα πολλαπλά φίλτρα που παρέχουμε στην εργασία μας. Που τα πειράματα μας και τα αποτελέσματα μας θα βασίζονται σε αυτό το πίνακα.

Μετά το πίνακα 3 που ουσιαστικά προσπαθεί να μας αποδείξει την προσεγγίσεις που παρέχει, έχουμε τους πίνακες 4-8 που αναλύει κάθε dataset που περιγράψαμε με της μεθόδους:

- Maximum Likelihood
- Laplace
- Scoring
- Max $\chi^2$

Αρχικά, ας κατανοήσουμε τους όρους αυτούς έτσι ώστε να καταλάβουμε και καλύτερα την προσέγγιση που ακολουθούμε.

**Maximum Likelihood**: Μια στατιστική μέθοδος για την εκτίμηση των παραμέτρων μιας κατανομής πιθανοτήτων, δεδομένων ορισμένων παρατηρούμενων δεδομένων. Λειτουργεί βρίσκοντας τις τιμές παραμέτρων που μεγιστοποιούν τη συνάρτηση πιθανότητας, η οποία αντιπροσωπεύει την πιθανότητα παρατήρησης των δεδομένων δεδομένων με βάση τις παραμέτρους. Με απλούστερους όρους, βρίσκει την κατανομή «καλύτερης προσαρμογής» για τα παρατηρούμενα δεδομένα.

**Laplace**: Είναι η μέθοδος που είναι μια τροποποιημένη εκδοχή του confidence, η οποία εφαρμόζει smoothing ώστε να μην ευνοούνται υπερβολικά οι κανόνες με πολύ λίγες εμφανίσεις. Κατά κάποιο τρόπο αυτό που προσπαθεί είναι να έχουμε δεδομένα humanized και όχι αυστηρά με την υπάρχουσα τεχνολογία.

**Scoring**: Διαφορετικά από τις άλλες μεθόδους, είναι μια εσωρετική αξιολογητική συνάρτηση που σχεδιάστηκε για τον συγκεκριμένο αλγόριθμο. Που δεν βασίζεται μόνο και μόνο στο support ή confidence όπως σε άλλες μεθόδους. Αλλά βασίζεται και σε πολλαπλές πτυχές της ποιότητες του κανόνα όπως το information gain και coverage.

**Max $\chi^2$:** Είναι ο στατικός όρος που θα εφαρμόσουμε για να ψάξουμε στατιστικά σημαντικούς κανόνες σε μεγάλα σύνολα. Η ιδέα είναι να εξετάσουμε αν η παρουσία του χ (σώμα του κανόνα) επηρεάζει στατιστικά την εμφάνιση της c (class label).

Η εξήγηση των ορολογιών στο πρακτικό μέρος της άσκησης θα μας διευκολίνει την κατανόηση των ορίων αλλά και οι λόγοι που προσφέρει.

Σαν πρώτο πίνακα με δείγματα πραγματικά έχουμε το πίνακα με dataset balance scale με τις 4 μεθόδους που περιλαμβάνουμε παραπάνω. Παρατηρούμε ότι το maximum likelihood παρουσιάζει την καλύτερη συνολική ακρίβεια που είναι μέχρι και 0.748 για minsup=0.02 και σ=0.1. Με την λιγότερη απόδοση να έχει η μέθοδος $\chi^2$ που είναι μέγιστο 0.39.

Ο πίνακας balance scale δεν περιέχει τα σπάνια αντικείμενα αλλά βλέπουμε ότι χαμηλές τιμές minsup και σ ευνοούν καλύτερη ακρίβεια.

Διαφορετικά από το πίνακα με balance scale, στο πίνακα με breast cancer έχουμε rare items kai ο MMSCBA έχει υψηλή απόδοση σε αντίθεση με αλγορίθμους που θα απέκλειαν σπάνιους αλλά κρίσιμους κανόνες.

Στο dataset Breast Cancer Wisconsin οι ακρίβειες είναι πολύ υψηλές διότι έχει και rare items αλλά και υψηλή ακρίβεια που με αυτό τον τρόπο επιβεβαιώνει την αποτελεσματικότητα του MMSCBA σε δύσκολα σενάρια και δείχνει ότι οι σπάνιοι κανόνες μπορούν να προσφέρουν υψηλή προβλεπτική ισχύ.

Το M2 dataset είναι πιθανώς πιο δύσκολο ή λιγότερο συνεκτικό. Ο MMSCBA παραμένει σταθερός αλλά δεν απογειώνεται κάτι που υποδηλώνει ότι εδώ ο τύπος των χαρακτηριστικών ή των patterns ίσως να μην ταιριάζει απόλυτα με τους κανόνες συσχέτισης.

Το TF dataset φαίνεται να ανταποκρίνεται εξαιρετικά στο MMSCBA, με ή χωρίς finetuning. Η σταθερότητα υποδεικνύει ότι το μοντέλο είναι ανθεκτικό και προβλέψιμο.

Στο τέλος του πρακτικού μέρους της εργασίας περιέχουμε τους πίνακες 9 και 10. Που παρουσιάζουν την συγκριτική αξιολόγηση ακριβείας ταξινόμησης και χρόνος εκτέλεσης αντίστοιχα.

Ο Πίνακας 9 παρουσιάζει την ακρίβεια ταξινόμησης του MMSCBA σε σύγκριση με έξι άλλους γνωστούς αλγορίθμους (CBA, RIPPER, PART, C4.5, ANN και SVM) σε έξι διαφορετικά σύνολα δεδομένων. Ο MMSCBA εμφανίζει πολύ καλές και σταθερές επιδόσεις. Σε ορισμένα datasets, όπως τα BS και BCW, αποδίδει καλύτερα από τους άλλους rule-based αλγορίθμους, ενώ η απόδοσή του πλησιάζει ή και φτάνει αυτή πιο εξελιγμένων μεθόδων όπως τα τεχνητά νευρωνικά δίκτυα και οι SVM.

Η διαφορά υπέρ του MMSCBA γίνεται ακόμα πιο ξεκάθαρη σε δεδομένα που περιέχουν σπάνια αλλά σημαντικά παραδείγματα, όπως τα BC και BCW. Χάρη στη χρήση διαφορετικών ορίων υποστήριξης (multiple minimum support), ο αλγόριθμος μπορεί να διατηρεί χρήσιμους κανόνες που άλλες μέθοδοι απορρίπτουν. Αυτό του επιτρέπει να πιάνει λεπτές αλλά κρίσιμες συσχετίσεις, προσφέροντας όχι μόνο υψηλή ακρίβεια αλλά και ερμηνευσιμότητα, κάτι που συχνά λείπει από πιο μαύρου κουτιού μοντέλα όπως τα ANN και SVM.

Ο Πίνακας 10 δείχνει τους χρόνους εκτέλεσης κάθε μεθόδου. Ο MMSCBA δεν είναι ο πιο γρήγορος, όμως οι χρόνοι του θεωρούνται απολύτως αποδεκτοί για πειραματική ή πρακτική χρήση. Σε μικρά ή μεσαίου μεγέθους σύνολα δεδομένων, ολοκληρώνει σε λίγα δευτερόλεπτα ή κάτω από ένα λεπτό. Σε μεγαλύτερα datasets, όπως το Waveform, ο χρόνος αυξάνεται (π.χ. περίπου 195 seconds), αλλά παραμένει καλύτερος από πιο βαριές μεθόδους όπως το ANN και το SVM.

Αν και είναι πιο αργός από τον CBA αυτό οφείλεται στη μεγαλύτερη πολυπλοκότητα του MMSCB, καθώς εφαρμόζει διαφορετικά όρια υποστήριξης ανά αντικείμενο (MIS). Παρ' όλα αυτά, το επιπλέον υπολογιστικό κόστος αντισταθμίζεται από τη βελτίωση στην ποιότητα των κανόνων και στην τελική ακρίβεια. Τέλος, ο MMSCBA αποτελεί μια πολύ καλή επιλογή για εφαρμογές όπου προέχει η ακρίβεια και η δυνατότητα ερμηνείας των αποτελεσμάτων, ακόμη και αν δεν είναι η πιο γρήγορη λύση.

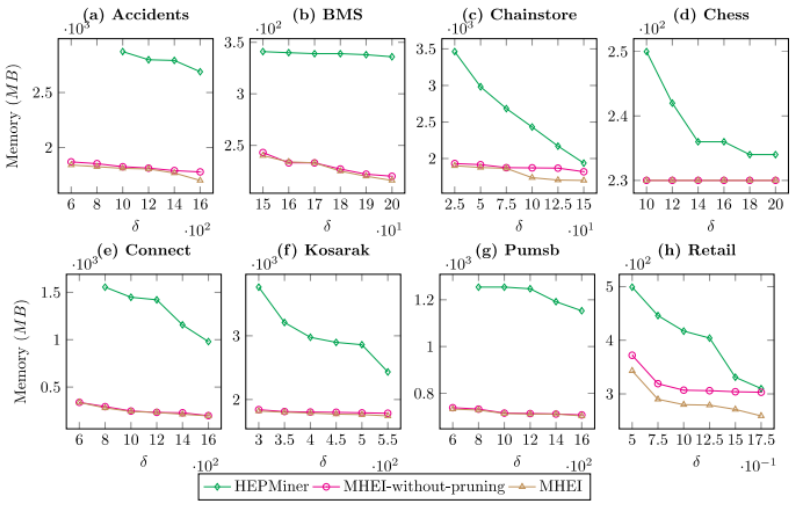
### 3.2.3 Πειραματική Αξιολόγηση 3ου Paper

Έχουμε το προτεινόμενο αλγόριθμο τον MHEI που ουσιαστικά θα κοιτάξουμε κατά πόσο δουλεύει. Για να καταλάβουμε αν είναι καλύτερος από παλιότερους τον συγκρίνουμε με δύο άλλους που είναι ο HEPM όπου είναι ένας γνωστός και βασικός αλγόριθμος και τον MHEI χωρίς pruning, που είναι ο ίδιος ο MHEI αλλά χωρίς τα έξυπνα μαθηματικά φίλτρα που βοηθούν στο κόψιμο των άχρηστων υπολογισμών.

Τα πειράματα έγιναν σε διάφορες βάσεις δεδομένων με διαφορετικές όψεις που αυτές οι βάσεις είχαν πολλές πληροφορίες και άλλες λίγες. Σε όλες αυτές τις βάσεις οι αλγόριθμοι δοκιμάστηκαν με διαφορετικά όρια αποδοτικότητας (δηλαδή διαφορετικές τιμές για το κατώφλι δ) για να δουν πώς αλλάζει η συμπεριφορά τους.

Σε κάθε δοκιμή υπολογίστηκαν τέσσερα πράγματα που ο πρώτος είναι ο χρόνος που χρειάζεται ο αλγόριθμος για να τελειώσει μετά σαν δεύτερο υπολογισμό πόση μνήμη (RAM) χρησιμοποιεί, πόσα πιθανά σύνολα ειδών εξετάζει και πώς τα πάει όταν μεγαλώνει η βάση δεδομένων. Με απλά λόγια, θέλουμε να δούμε ποιος αλγόριθμος είναι πιο γρήγορος, ποιος καταναλώνει λιγότερη μνήμη, ποιος αποφεύγει να κάνει περιττή δουλειά και ποιος αντέχει καλύτερα σε δύσκολες περιπτώσεις.

Εν τέλει καταλήγουμε ότι ο MHEI έχει το καλύτερο αποτέλεσμα αφού δεν μεγαλώνει η βάσει και ξέρει σε ποια σημεία δεν χρειάζεται περαιτέρω αξιολόγηση με αποτέλεσμα να έχουμε τον καλύτερο από τους 3 αφού είναι και ο γρηγορότερος. Με αποτέλεσμα να καταλάβουμε ότι ο MHEI δεν είναι απλώς ο καλύτερος στην θεωρία αλλά και στην πράξη.




**Εικόνα 12.** Σύγκριση Κατανάλωσης Μνήμης των Αλγορίθων

Παρατηρούμε ότι ο αλγόριθμους MHEI έχει την λιγότερη κατανάλωση όπως έχουμε αναφερθεί και παραπάνω,

### 3.2.4 Πειραματική Αξιολόγηση 4ου paper

Έχουμε τρία σημαντικά μέρη όπου είναι το πειραματικό περιβάλλον, η σύγκριση του MHUI-MUT με τον προηγούμενο αλγόριθμο MHUI και με την παραλληλοποιημένη έκδοση δηλαδή PMHUI-MUT.

Στο πειραματικό μέρος της μελέτης, όλες οι υλοποιήσεις έχουν γίνει στον ίδιο υπολογιστή με επεξεργαστή Ryzen 3600, ο οποίος διαθέτει 6 φυσικούς πυρήνες (12 threads), και συνοδεύεται από 24 GB μνήμη RAM, λειτουργώντας σε περιβάλλον Windows 10. Όλοι οι αλγόριθμοι έχουν υλοποιηθεί σε γλώσσα Java, και οι μετρήσεις του χρόνου και της κατανάλωσης μνήμης έχουν πραγματοποιηθεί μέσω της Java API.

Ο παλαιότερος αλγόριθμος MHUI χρησιμοποιούσε ένα σταθερό κατώφλι minUtil για να αποφασίσει αν ένα σύνολο είναι υψηλής χρησιμότητας. Ο νέος αλγόριθμος MHUI-MUT, αντίθετα χρησιμοποιεί το **GLMU** που είναι ένα δυναμικά υπολογιζόμενο κατώφλι, διαφορετικό για κάθε αντικείμενο. Η τιμή αυτή προκύπτει μέσω του τύπου:

$$MU(i_k) = \max(\Delta * p(i_k), GLMU)$$

**Εικόνα 13.** Ορισμός του MU($i_k$) με συντελεστή GLMU

όπου p($i_k$) είναι το κέρδος του αντικειμένου και Δ=GLMU\100. Αυτό αποφεύγει την υπερβολικά μικρή τιμή για το κατώφλι που θα μπορούσε να προκαλέσει υπερφόρτωση με πολλές άχρηστες εξορύξεις.

Η απόδοση του νέου αλγορίθμου MHUI-MUT συγκρίθηκε με τον προηγούμενο MHUI με βάση τρία κριτήρια: (1) τον χρόνο εκτέλεσης, (2) την κατανάλωση μνήμης και (3) τον αριθμό των υποψήφιων συνόλων που παράγονται κατά την εξόρυξη.

Οι βάσεις δεδομένων που χρησιμοποιήθηκαν προέρχονται από το SPMF και περιλαμβάνουν τόσο πυκνές όσο και αραιές δομές με ποικιλία στο μέγεθος και στα χαρακτηριστικά εξασφαλίζοντας ολοκληρωμένη αξιολόγηση του αλγορίθμου.

Ο MHUI-MUT αποδείχθηκε σημαντικά ταχύτερος από τον MHUI. Σε κάποιες βάσεις, η εκτέλεση ήταν έως και 3000 φορές γρηγορότερη κυρίως λόγω της συγχώνευσης συναλλαγών και της χρήσης αποδοτικών τεχνικών pruning.

Έπειτα, η χρήση μνήμης ήταν επίσης σημαντικά μειωμένη ιδίως σε πυκνές βάσεις. Σε κάποιες περιπτώσεις η κατανάλωση μνήμης ήταν 10 φορές μικρότερη καθώς ο αλγόριθμος αποφεύγει τη δημιουργία πολλών προβαλλόμενων βάσεων.

Ο αριθμός των υποψήφιων συνόλων που δημιουργεί ο MHUI-MUT είναι πολύ μικρότερος ειδικά σε αραιές βάσεις μειώνοντας έτσι και τον χρόνο και τη μνήμη. Η παραλλαγή pMHUI-MUT αξιοποιεί πολλούς επεξεργαστές για να μειώσει περαιτέρω τον χρόνο εξόρυξης. Οι μεγαλύτερες βάσεις χρησιμοποιήθηκαν εδώ για να φανεί καλύτερα η αποδοτικότητα της παραλληλοποίησης.

Η αύξηση των επεξεργαστών οδηγεί σε μικρότερους χρόνους, αλλά όχι γραμμικά – με 4 πυρήνες ο χρόνος μειώνεται έως και 3,3 φορές, ενώ με 8 έως και 5,5. Η απόδοση επηρεάζεται από την άνιση κατανομή του υπολογιστικού φόρτου. Η χρήση περισσότερων επεξεργαστών αυξάνει τη συνολική μνήμη, επειδή κάθε πυρήνας κρατά ξεχωριστά δεδομένα, αλλά η αύξηση αυτή δεν είναι απαγορευτική.

Τέλος, η σχέση εξοικονόμησης χρόνου προς την αύξηση της μνήμης δείχνει ότι η παραλληλοποίηση είναι αποδοτική και βελτίωση στον χρόνο είναι περίπου διπλάσια από την αύξηση της μνήμης.

## 4 Μετέπειτα Εργασίες

Σαν μετέπειτα εργασίες έχουμε κάποια paper που σύμφωνα με τις μελέτες που είχαμε θα μπορούσε να μας βοηθήσει κοιτάζοντας τις μελλοντικές μελέτες (future work) που έχουμε σε κάθε paper που έχουμε παρουσιάσει.

Αρχικά, έχουμε την εργασία [16] που αφορά τη δυνατότητας της προσέγγισης σε άλλους τύπους συνόλων δεδομένων. Προηγούμενες μελέτες έχουν προτείνει διάφορους παράγοντες που είναι χρήσιμοι σε συγκεκριμένες περιπτώσεις. Παρόλο αυτό αυτοί οι παράγοντες είναι συχνά ανεφάρμοστοι για την ανάλυση νέων δεδομένων.

Σαν αποδοτικότητα αποτελεί βασικό ζήτημα στις μεθόδους ταξινόμησης βάσει συσχετίσεων ιδιαίτερα όταν χρησιμοποιούνται αλγόριθμοι τύπου Apriori. Που είναι υπολογιστικά απαιτητικός λόγω της παραγωγής μεγάλου αριθμού υποψήφιων κανόνων και πολλαπλών σαρώσεων της βάσης δεδομένων. Για την αντιμετώπιση αυτών των περιορισμών προτείνεται η χρήση εναλλακτικών τεχνικών όπως ο FP-Growth, ο οποίος προσφέρει σημαντική βελτίωση στην ταχύτητα, αποφεύγοντας την παραγωγή υποψηφίων και αξιοποιώντας αποδοτικές δομές δεδομένων (FP-tree). Επιπλέον, η διαχωρισμένη επεξεργασία της εξόρυξης κανόνων από την ταξινόμηση, καθώς και η χρήση στρατηγικών pruning, ενισχύουν την αποδοτικότητα χωρίς απώλεια ακρίβειας.

Ουσιαστικά η εργασία [16] είναι μία μετέπειτα εργασία της μελέτης “Building an associative classifier with multiple minimum supports” όπου θα εξετάσουμε διαφορές και καλύτερες προσεγγίσεις που παρέχουμε για την νέα μας εργασία που είναι και ποιο πρόσφατη (2018).

Η εργασία του 2018 αποτελεί μια θεμελιώδη εξέλιξη σε σχέση με την MMSCBA του 2016. Περιλαμβάνει ισχύ επεξεργασίας που στοχεύουν στην επεξεργασία τεράστιων datasets με 4+ billion εγγραφές,1.2TB+ δεδομένα και 800 εκατομμύρια διακριτές κατηγορίες που είναι μία μεγάλη διαφορά σε σχέση με προηγούμενη εργασία.

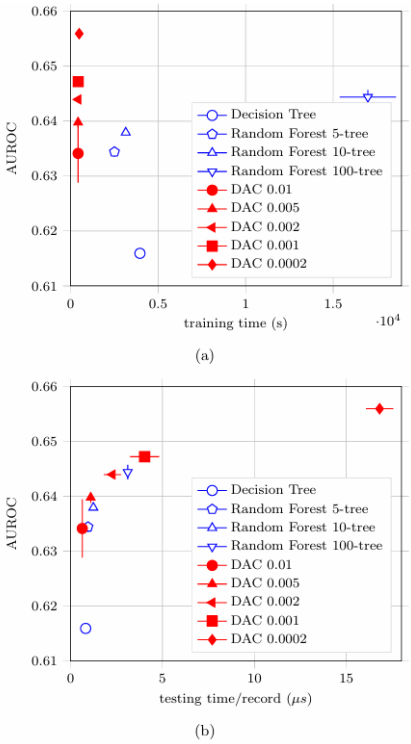
Σαν κεντρική καινοτομία έχει τον αλγόριθμο CAP-growth που έχει μία διαφορετική προσέγγιση σε σχέση με τους παραδοσιακούς αλγορίθμους. Αντί να εξάγει όλους τους πιθανούς κανόνες και στη συνέχεια να τους κλαδεύει όπως κάνει η MMSCBA η CAP-growth χρησιμοποιεί την ακαθαρσία Gini για να παράγει άμεσα μόνο χρήσιμους κανόνες ταξινόμησης. Ο αλγόριθμος ταξινομεί τα συχνά στοιχεία με βάση το Κέρδος Πληροφορίας τους και εφαρμόζει άπληστη προσέγγιση για την εξαγωγή κανόνων υψηλής ποιότητας.

Αν αναλύσουμε την αρχιτεκτονική, εισάγει μια εντελώς νέα κατανεμημένη προσέγγιση βασιζμένη σε Apache Spark και in-memory cluster computing. Χρησιμοποιεί ensemble learning για να κατανείμει την εκπαίδευση μεταξύ παράλληλων εργατών, σε αντίθεση με την προσέγγιση μίας μηχανής της MMSCBA. Η εργασία εισάγει επίσης προχωρημένες τεχνικές ενοποίησης μοντέλου που συνδυάζουν κανόνες με πανομοιότυπο προηγούμενο και επόμενο, χρησιμοποιώντας συναρτήσεις συγκέντρωσης όπως max, min ή γινόμενο για τις μετρικές των κανόνων.

Τα αποτελέσματα απόδοσης δείχνουν εντυπωσιακές βελτιώσεις στη DAC. Ενώ ένα 100-δέντρων Random Forest χρειάστηκε 30 ώρες για εκπαίδευση, η DAC ολοκλήρωσε την εκπαίδευση σε 20 ώρες, παρέχοντας ταυτόχρονα καλύτερη ποιότητα πρόβλεψης (AUROC κατά 1% υψηλότερο). Αυτό σημαίνει ότι η DAC είναι περίπου 25 φορές

ταχύτερη από ανταγωνιστικές μεθόδους ενώ παρέχει ανώτερα αποτελέσματα. Επιπλέον, όταν εφαρμόζεται database coverage pruning ως τελικό βήμα, μόνο ένα αμελητέο κλάσμα κανόνων (κάτω από 5%) χρειάζεται κλάδεμα, αποδεικνύοντας την αποτελεσματικότητα της προληπτικής προσέγγισης.

Βέβαια καταλαβαίνουμε ότι έχουμε καλύτερη προσέγγιση σαν μελλοντική εργασία αλλά μην ξεχάσουμε ότι έχουμε και διαφορετική κλίμακα. Που σημαίνει σε σχέση με future work θα μπορούσε να γίνει μία συσχέτιση μεταξύ των 2 εργασιών για μία νέα έρευνα.




**Εικόνα 14**. Σύγκριση Απόδοσης DAC vs Random Forest: Ποιότητα και Ταχύτητα

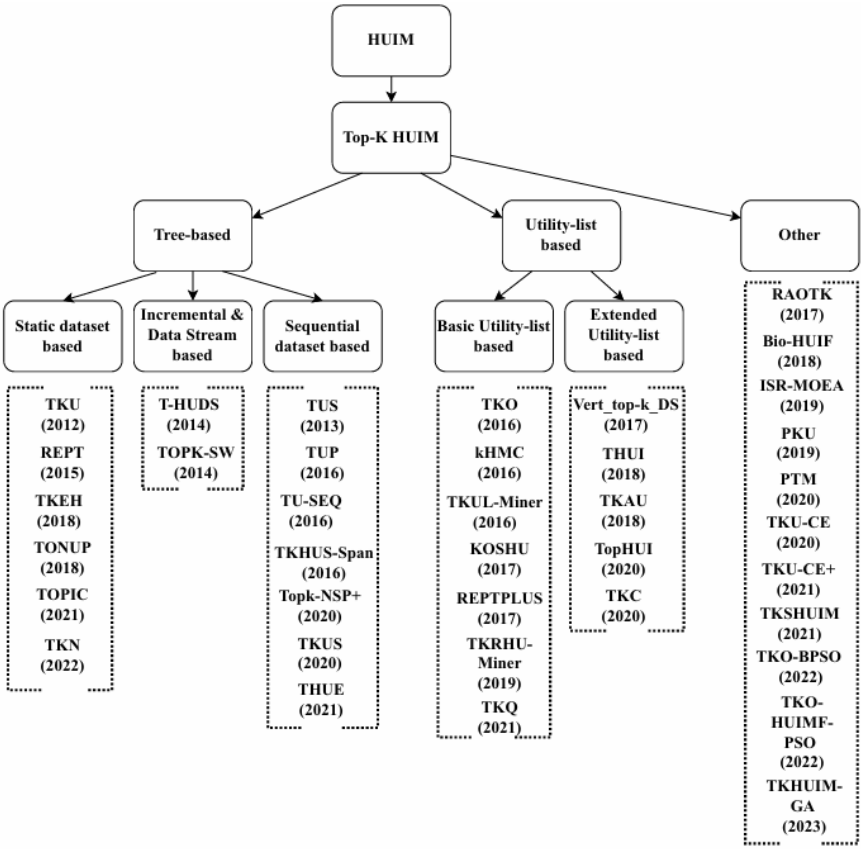
Η εικόνα 14 δείχνει ότι το DAC είναι σαφώς ανώτερο από το Random Forest τόσο σε ποιότητα όσο και σε ταχύτητα. Στο πάνω γράφημα βλέπουμε ότι το DAC με minimum support 0.0002 (κόκκινο διαμάντι) πετυχαίνει το υψηλότερο AUROC (~0.655) ενώ χρειάζεται μόλις 500 δευτερόλεπτα για εκπαίδευση, σε αντίθεση με το Random Forest 100-tree που χρειάζεται 15,000 δευτερόλεπτα (30 φορές περισσότερο χρόνο) για χειρότερο αποτέλεσμα (~0.644). Στο κάτω γράφημα φαίνεται ότι το DAC διατηρεί την ανωτερότητά του και στον χρόνο testing ανά εγγραφή, παρέχοντας καλύτερη ακρίβεια με παρόμοιο testing time. Αυτό αποδεικνύει ότι το DAC δεν είναι απλώς επεκτάσιμο για μεγάλα datasets, αλλά προσφέρει και καλύτερη απόδοση με δραματικά μειωμένους χρόνους εκπαίδευσης - ένας συνδυασμός που το καθιστά ιδανικό για πραγματικές εφαρμογές big data.

Μία άλλη εργασία που θα μπορούσε να είναι σαν μία μελλοντική εργασία θα ήταν η μελέτη [17] που παρουσιάζει σημαντικά πλεονεκτήματα που το καθιστούν κατάλληλη μελλοντική εργασία. για το πεδίο του High-Efficiency Itemset Mining (HEIM) που θα ήταν η επέκταση της εργασίας “ An efficient strategy for mining high-efficiency itemsets in quantitative databases ”. Ένα από τα βασικά θετικά του είναι ότι εξαλείφει την ανάγκη καθορισμού αυθαίρετου κατωφλίου ελάχιστης χρησιμότητας (min_util) αντικαθιστώντας το με την επιλογή των k κορυφαίων συνόλων αντικειμένων με τη μεγαλύτερη

χρησιμότητα. Αυτό επιτρέπει πιο ευέλικτη και φιλική προς τον χρήστη εξόρυξη γνώσης, καθώς οι χρήστες μπορούν να ζητούν απλώς τα 10 πιο αποδοτικά σύνολα χωρίς τεχνικές γνώσεις.

Επιπλέον, η εργασία καλύπτει πάνω από 35 σύγχρονους αλγόριθμους, προτείνοντας καινοτόμες τεχνικές βελτιστοποίησης όπως threshold raising στρατηγικές που μειώνουν τον αριθμό υποψηφίων και τη μνήμη που απαιτείται. Οι τεχνικές αυτές που είναι οι στρατηγικές PE, NU, RIU, EUCS μπορούν να μεταφερθούν στην εξόρυξη υψηλής αποδοτικότητας (HEIM), ώστε να βελτιώσουν περαιτέρω την αποδοτικότητα σε όρους χρόνου, μνήμης και scalability.

Η μεθοδολογία top-k μπορεί να συνδυαστεί με την έννοια της αποδοτικότητας (efficiency = κέρδος / επένδυση) που εισήγαγε το HEIM προσφέροντας έναν μηχανισμό top-k HEI. Αυτό θα αφαιρούσε την ανάγκη για αυθαίρετο κατώφλι δ και θα επέτρεπε την εξαγωγή των k πιο συμφερουσών ομάδων αντικειμένων βάσει της επενδυτικής τους αποδοτικότητας. Έτσι, το άρθρο για το top-k HUIM δεν είναι μόνο ένα ισχυρό θεωρητικό υπόβαθρο αλλά και μια φυσική προέκταση για την εξέλιξη του πεδίου HEIM.




**Εικόνα 15.** Ταξινομία των πλέον σύγχρονων αλγορίθμων εξόρυξης συνόλων υψηλής χρησιμότητας με top-k προσέγγιση

Η εικόνα 15 αποτελεί μια συνοπτική ταξινόμηση των υπαρχόντων αλγορίθμων στον τομέα του Top-k High Utility Itemset Mining και μπορεί να χρησιμοποιηθεί ως θεμέλιο για μελλοντικές εργασίες στο HEIM. Πιο συγκεκριμένα, παρουσιάζει οργανωμένα τους αλγορίθμους ανά κατηγορία (tree-based, utility-list-based, sequential, data-stream, hybrid), δίνοντας τη δυνατότητα στον ερευνητή να εντοπίσει ποιες τεχνικές είναι πιο αποδοτικές και πού μπορούν να εφαρμοστούν.

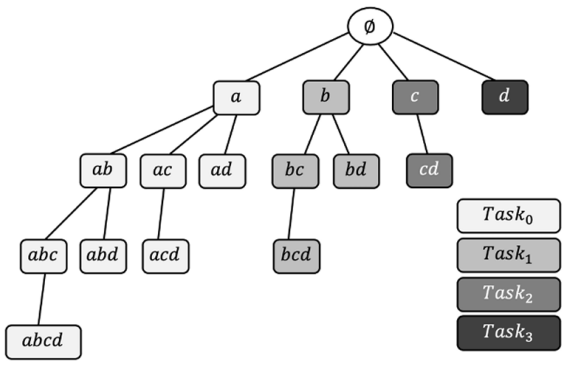
Αυτό είναι ιδιαίτερα χρήσιμο για την ανάπτυξη ενός Top-k HEIM αλγορίθμου δηλαδή ενός συστήματος που δεν θα απαιτεί κατώφλι αποδοτικότητας, αλλά θα επιστρέφει απευθείας τα k πιο αποδοτικά σύνολα αντικειμένων. Οι τεχνικές που φαίνονται στην εικόνα, όπως το threshold raising, η χρήση utility-list δομών και η συγχώνευση συναλλαγών μπορούν να μεταφερθούν και να προσαρμοστούν στο πλαίσιο της αποδοτικότητας (efficiency = κέρδος / επένδυση).

Μία άλλη μετέπειτα εργασία είναι η [18] που παρουσιάζει μια σημαντική συνεισφορά στον τομέα της εξόρυξης συνόλων αντικειμένων υψηλής χρησιμότητας (HUIs) εστιάζοντας ειδικά σε βάσεις δεδομένων με δυναμικά κέρδη. Θα προσπαθήσουμε να επεκτείνουμε την εργασία " New approaches for mining high utility itemsets with multiple utility thresholds".

Μία από τις βασικές θετικότητες του άρθρου είναι ότι αναγνωρίζει μια πολύ ρεαλιστική πτυχή των πραγματικών δεδομένων που ότι οι τιμές κέρδους των αντικειμένων δεν είναι σταθερές αλλά αλλάζουν με την πάροδο του χρόνου λόγω εκπτώσεων και αλλαγών κόστους. Σε αυτό το πλαίσιο προτείνει έναν νέο τύπο βάσης δεδομένων την dynamic profit database και μια αντίστοιχα προσαρμοσμένη μεθοδολογία εξόρυξης HUIs που λαμβάνει υπόψη αυτή τη δυναμική.

Ένας δεύτερος ισχυρός παράγοντας του άρθρου είναι η εισαγωγή του αλγορίθμου MCH-Miner που βασίζεται σε επεκτάσεις του iMEFIM και αξιοποιεί πολυπύρηνη επεξεργασία (multi-core parallelism) για να επιταχύνει την εξόρυξη. Ο αλγόριθμος αυτός υιοθετεί αποτελεσματικές τεχνικές όπως προβολή βάσης ή αλλιώς projection, συγχώνευση συναλλαγών (transaction merging) και τη δομή P-set για μείωση των περιττών σκαναρισμάτων βελτιώνοντας έτσι τόσο τον χρόνο εκτέλεσης όσο και την κατανάλωση μνήμης. Τα πειραματικά αποτελέσματα δείχνουν ότι το MCH-Miner είναι σημαντικά ταχύτερο από προγενέστερους αλγορίθμους, διατηρώντας παράλληλα ακρίβεια σε περιβάλλοντα με μεταβαλλόμενα κέρδη.

Και τα δύο άρθρα προσφέρουν σημαντικά πλεονεκτήματα: το πρώτο (MCH-Miner) υποστηρίζει δυναμικά κέρδη και αποδοτική πολυπύρηνη επεξεργασία ενώ το δεύτερο (MHUI-MUT) εισάγει πολλαπλά κατώφλια χρησιμότητας και προηγμένες τεχνικές περικοπής. Μια μελλοντική εργασία που θα συνδυάζει αυτά τα στοιχεία θα μπορούσε να εξορύσσει HUIs σε δυναμικά και πολύπλοκα περιβάλλοντα, με υψηλή ακρίβεια και ταχύτητα, αξιοποιώντας πλήρως τις δυνατότητες των σύγχρονων υπολογιστικών συστημάτων.




**Εικόνα 16.** Ο κατανεμημένος χώρος αναζήτησης που χρησιμοποιείται από τον αλγόριθμο MCH-Miner.

Βλέπουμε ότι παρουσιάζεται τον κατανεμημένο χώρο αναζήτησης σε ξεχωριστά tasks για πολυπύρηνη επεξεργασία. Σε αντίθεση με πιο απλές παραλληλοποιήσεις εδώ ο αλγόριθμος χωρίζει έξυπνα το δέντρο των υποψήφιων συνόλων και κατανέμει τις εργασίες σε διαφορετικούς πυρήνες επιτυγχάνοντας έτσι καλύτερη εκμετάλλευση των διαθέσιμων πόρων και σημαντική επιτάχυνση. Η εικόνα 16 αποδεικνύει καθαρά ότι το MCH-Miner δεν είναι απλώς παραλληλοποιημένο, αλλά έχει σχεδιαστεί για αποτελεσματική κατανομή φόρτου, κάτι που το καθιστά πιο αποδοτικό σε μεγάλα και απαιτητικά datasets.

# 5 Σύνοψη και Συμπεράσματα

## 5.1 Σύνοψη

Αν ξεκινήσουμε την περιγραφή συνοπτικά η εργασία μας εστιάζει στην εξόρυξη με ιδιαίτερη έμφαση σε τεχνικές εξόρυξης συσχετιστικών κανόνων. Που οι κλασικοί αλγόριθμοι δεν είναι και η καλύτερη που βασίζονται στη συχνότητα.

Που ασχολούμαστε με νέες τεχνικές που θα μπορούν να υπάρχει μία βελτίωση με προηγούμενες εργασίες. Για αυτό το λόγο έχουμε και κάποιες κατηγορίες όπως οι περιορισμοί. Είναι κανόνες που ορίζουν ποιοι συσχετισμοί επιτρέπονται ή αξίζουν να εξορισθούν. Παρόλο που φαίνεται μία απλή μέθοδο μας γλιτώνει πάρα πολύ χρόνο με τις μεθόδους που έχουμε υλοποιήσει.

Έπειτα τα πολλαπλά κατώφλια υποστήριξης που μας καθοδηγεί σε μία ποιο λεπτομερείς εξόρυξη με κάθε αντικείμενο να έχει το δικό του κατωφλιού με αποτέλεσμα να έχουμε ακόμα και τα χρήσιμα σπάνια αντικείμενα που μπορούν να βασιστούν σε μία θέση.

Η αποδοτικότητα που αξιολογεί τα αντικείμενα και με πόσα κερδοφόρα είναι για να καταλάβουμε αν χρειάζεται κάποιο αντικείμενο αναλόγως με την «τιμή» του που θα μπορούμε να έχουμε και μία σύγκριση ακόμα και με το μάτι για τα αποτελέσματα.

Στην συνέχεια το MHUI-MUT που διαφορετικά εδώ βλέπουμε την χρησιμότητα ανάλογα με τη σημασία του.

Με αυτές τις αρχικές μεθόδους ουσιαστικά αυτό που καταφέρνει η εργασία είναι η εξατομίκευση αποτελεσμάτων με βάση χρήσιμους περιορισμούς, αντιμετωπίζει το rare item problem, εισάγει μία νέα μέθοδο αποδοτικότητας και διαφοροποιεί τα χρηστικά προϊόντα.

Συνεχίζουμε την θεωρητική προσέγγιση της εργασία αρχικά έχουμε την υποστήριξη που μετρά την συχνότητα εμφάνισης, που με αυτό τον τρόπο καταλαβαίνουμε πόσο συχνά εμφανίζεται κάποιο δεδομένο.

Μετά, η εμπιστοσύνη δείχνει την αξιοπιστία του κανόνα που ουσιαστικά βγάζουμε κάποιο ποσοστό για μία γενική όψη. Όπως και η χρησιμότητα  για να λήψη απόφασης.

Οι ενδιαφέρον κανόνες, όπως οι μονοτονικοί περιορισμοί που αν ισχύει ένα σύνολο αντικειμένων αυτό σημαίνει ότι ισχύει και για τα άλλα υπερσύνολα.

Για παράδειγμα, αν έχουμε τον περιορισμό ότι το συνολικό κόστος πρέπει να είναι μικρότερο από μια ελάχιστη τιμή, τότε αν ένα σύνολο αντικειμένων πληροί αυτόν τον περιορισμό, οποιοδήποτε μεγαλύτερο σύνολο που περιέχει αυτά τα αντικείμενα θα τον

πληροί επίσης. Αυτό επιτρέπει πιο αποδοτική αναζήτηση και μείωση του υπολογιστικού φόρτου.

Που σαν αντίθετο αυτής της σχέσης έχουμε και τους αντιμονοτικούς περιορισμούς. Όπου αν δεν ισχύει για ένα σύνολο αντικειμένων κάποιος περιορισμός, σημαίνει ότι δεν θα ισχύει και για τα υπερσύνολα του.

Η σχέση που συνδέει αυτές τις προηγούμενες μεθοδολογίες είναι οι μετατρέψιμου περιορισμοί που ουσιαστικά μπορεί να μετατραπεί ο ένας κανόνας στον άλλο.

Παρουσιάζουμε λήμματα που μας βοήθησαν για τις αποδείξεις και για κατανόηση της θεωρίας στο θεωρητικό περιβάλλον της εργασίας.

Δέντρα περιορισμού που χρησιμοποιούνται για να αποθηκεύουν τους συνδυασμούς των αντικειμένων που εξετάζονται. Αντί να αποθηκεύονται όλα τα πιθανά σύνολα αντικειμένων τα prefix trees οργανώνουν τα αντικείμενα κατά τρόπο ώστε να μειώσουν την αναγκαία μνήμη και να επιταχύνουν την αναζήτηση. Ώστε στην συνέχεια να χρησιμοποιήσουμε τις συναλλακτικές βάσεις δεδομένων ή αλλιώς conditional databases που θα οργανώσουν τα δεδομένα κατά τέτοιο τρόπο ώστε να υπάρχουν αποτελέσματα μόνο που θα ικανοποιήσουν τον περιορισμό. Που συνοδευτικά έχουμε το MIS μαζί με τα άνω όρια.

Σαν πρακτικό μέρος η εργασία μας βασίζεται σε πολλά πειράματα που κατά κάποιο τρόπο το κάθε πείραμα συνδέεται με μία προηγούμενη. Δηλαδή υπάρχουν σχετικές προσεγγίσεις για μία ολόκληρη και σωστή εργασία.

Όπως το MMSCBA που περιέχει 6 datasets και συγκρίνει γνωστούς αλγορίθμους CBA, SVM, ANN. Άλλη μία προσέγγιση το HEIM που στο παράδειγμα μας είναι για αποδοτικότητα του κάθε itemset και χρησιμοποιεί φιλτράρισμα με αυστηρότερα local/subtree bounds. Τέλος, MHUI-MUT που έχει μία ποιο έξυπνη εφαρμογή φίλτρων και προβολών μαζί με merging transactions.

### 5.2 Συμπεράσματα

Τα συμπεράσματα που βγάζουμε από την εργασία είναι ότι υπάρχουν πάρα πολλές αναλυτικές προσεγγίσεις με την έννοια αλγορίθμου αλλά και κατώφλι μαζί με διάφορους περιορισμούς για μία ποιο «καθαρή» εξόρυξη και χρήσιμο αποτέλεσμα.

Η εξόρυξη γνώσης χρειάζεται να προσαρμοστεί στις πραγματικές ανάγκες των χρηστών και των δεδομένων που έχουν ποιοτικά χαρακτηριστικά και όχι μόνο ποσότητα. Οι παραδοσιακοί αλγόριθμοι που βασίζονται μόνο στη συχνότητα δεν είναι πλέον αρκετοί για σύνθετα περιβάλλοντα εφαρμογής αφού αποτυγχάνουν να εντοπίσουν ουσιαστικά και χρήσιμα πρότυπα που απαιτούν μια πιο ευφυή ανάλυση της πληροφορίας

Η χρήση περιορισμών στην εξόρυξη κανόνων βοηθά στην αποφυγή άχρηστων συσχετίσεων και προσφέρει μεγαλύτερη ακρίβεια δίνοντας στον χρήστη τον έλεγχο να καθορίσει τι είναι σχετικό για τον ίδιο. Τα πολλαπλά κατώφλια υποστήριξης επιτρέπουν την αναγνώριση και αξιοποίηση σπάνιων αλλά σημαντικών αντικειμένων. Αυτό καθιστά τους αλγορίθμους πιο ευέλικτους και πιο κατάλληλους για πολύπλοκες πραγματικές εφαρμογές

Η αποδοτικότητα ως μέτρο αξιολόγησης δηλαδή το πόσο αξίζει ένα σύνολο αντικειμένων σε σχέση με το κόστος του εισάγει μια πιο ρεαλιστική προσέγγιση στην ανάλυση, Ειδικά σε περιβάλλοντα όπως τα εμπορικά συστήματα είναι κρίσιμο να εντοπίζονται. Η εισαγωγή πολλαπλών χρηστικών κατωφλίων και η παραλληλοποίηση της επεξεργασίας ενισχύουν περαιτέρω την αποδοτικότητα των συστημάτων εξόρυξης γνώσης κάτι που τα καθιστά ικανά να λειτουργούν με μεγάλα και πολύπλοκα δεδομένα σε πραγματικό χρόνο

Τέλος, οι προτεινόμενοι αλγόριθμοι δείχνουν καλύτερη ακρίβεια και αποτελεσματικότητα σε σύγκριση με παλαιότερες τεχνικές σύμφωνα με τα πειραματικά αποτελέσματα και αυτό αποδεικνύει ότι η σύνδεση των τεχνικών με πρακτικά προβλήματα δεν είναι μόνο επιθυμητή αλλά απαραίτητη. Η εργασία αυτή καταδεικνύει ότι η εξέλιξη των μεθόδων εξόρυξης γνώσης προς πιο σύνθετα και ευέλικτα μοντέλα είναι αναγκαία για την κάλυψη των αναγκών του σύγχρονου αναλυτικού περιβάλλοντος καθώς με την βελτιστοποίηση της τεχνητής νοημοσύνης ο συγκεκριμένος κλάδος θα γίνει και ποιο χρήσιμος όσον αναφορά το ερευνητικό μέρος του κλάδου.

## Βιβλιογραφία


[1] R. T. Ng, L. V. S. Lakshmanan, J. Han, and A. Pang, “Exploratory mining and pruning optimizations of constrained association rules,” in *Proceedings of the ACM SIGMOD International Conference on Management of Data*, Seattle, WA, USA, 1998, pp. 13–24.

[2] M. El-Hajj, O. R. Zaïane, and P. Nalos, “Bifold constraint-based mining by simultaneous monotone and anti-monotone checking,” in *Proceedings of the 5th IEEE International Conference on Data Mining (ICDM)*, Houston, TX, USA, 2005, pp. 645–648.

[3] A. J. T. Lee, W. C. Lin, and C. S. Wang, “Mining association rules with multi-dimensional constraints,” *Journal of Systems and Software*, vol. 79, no. 1, pp. 79–92, 2006.

[4] J. Pei, J. Han, and L. V. S. Lakshmanan, “Mining frequent itemsets with convertible constraints,” in *Proceedings of the 17th International Conference on Data Engineering (ICDE)*, Heidelberg, Germany, 2001, pp. 433–442.

[5] B. Liu, W. Hsu, and Y. Ma, “Mining association rules with multiple minimum supports,” in *Proceedings of the 5th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, San Diego, CA, USA, 1999, pp. 337–341.

[6] B. Liu, W. Hsu, and S. Chen, “Integrating classification and association rule mining,” in *Proceedings of the 4th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)*, New York, NY, USA, 1998, pp. 80–86.

[7] F. Thabtah, “A review of associative classification mining,” *The Knowledge Engineering Review*, vol. 22, no. 1, pp. 31–47, 2007.

[8] W. Li, S. Ma, and W. H. S. H. W. H., “CMAR: Accurate and efficient classification based on multiple class-association rules,” in *Proceedings of the 1st IEEE International Conference on Data Mining (ICDM)*, San Jose, CA, USA, 2001, pp. 109–116.

[9] H. Yao, H. J. Hamilton, and C. J. Butz, “A foundational approach to mining itemset utilities from databases,” in *Proceedings of the 2004 SIAM International Conference on Data Mining*, 2004, pp. 482–486.

[10] S. Zida et al., “Efficient high-utility itemset mining using EFIM,” in *Proceedings of the 24th International Symposium on Methodologies for Intelligent Systems*, 2017, pp. 169–181.

[11] J. Zhang et al., “HEPMiner: Efficiently mining high-efficiency patterns in transactional databases,” *Information Sciences*, vol. 637, pp. 729–748, 2023.

[12] Y. Liu, W. K. Liao, and A. Choudhary, “A two-phase algorithm for fast discovery of high utility itemsets,” in *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, vol. 3518, 2005, pp. 689–695, doi: 10.1007/11430919_79.

[13] P. Fournier-Viger, C.-W. Wu, S. Zida, and V. S. Tseng, “FHM: faster highutility itemset mining using estimated utility co-occurrence pruning,” in *Lecture notes in computer science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, vol. 8502, 2014, pp. 83–92, doi: 10.1007/978-3-319-08326-1_9.

[14] S. Zida, P. Fournier-Viger, J. C.-W. Lin, C.-W. Wu, and V. S. Tseng, “EFIM: a fast and memory eficient algorithm for high-utility itemset mining,” *Knowl Inf Syst*, vol. 51, no. 2, pp. 595–625, 2017.

[15] S. Krishnamoorthy, “Efficient mining of high utility itemsets with multiple minimum utility thresholds,” *Eng Appl Artif Intell*, vol. 69, pp. 112–126, 2018.

[16] L. Venturini, E. Baralis, and P. Garza, “Scaling associative classification for very large datasets,” in *Proceedings of the 2016 IEEE International Conference on Data Mining Workshops (ICDMW)*, Barcelona, Spain, 2016, pp. 1060-1067.

[17] R. Kumar and K. Singh, “Top-k high utility itemset mining: current status and future directions,” *The Knowledge Engineering Review*, vol. 39, pp. e5, 1–61, 2024, doi: 10.1017/S0269888924000055.

[18] B. Vo, L. T. T. Nguyen, T. D. D. Nguyen, P. F. Viger, and D. T. Nguyen, “A multi-core approach to efficiently mining high-utility itemsets in dynamic profit databases,” *IEEE Access*, vol. 8, pp. 86321-86333, 2020, doi: 10.1109/ACCESS.2020.2992729.